Realización de caso estudio bodega de datos: Spring Valley

Evidencia GA4-210602033-AA1-EV03

[Nombre del aprendiz]

Servicio Nacional de Aprendizaje (SENA)

Tecnólogo en Implementación y gestión de bases de datos — Ficha [número de ficha]

Instructores: Miguel Andrés Arévalo Vela y Carlos Alberto Fuel Tulcán

[Centro de formación], [Ciudad]

[Fecha de entrega]

Introducción

Las empresas que crecen apoyadas en su infraestructura de tecnología acumulan grandes volúmenes de datos en sistemas diseñados para operar, no para analizar. En el caso de estudio de esta evidencia, la empresa Spring Valley sufrió un colapso de su sistema transaccional durante la facturación, cuando se intentaron ejecutar sobre él consultas históricas complejas para la toma de decisiones de la dirección. La solución propuesta es construir una bodega de datos (data warehouse) para el área de ventas, separada del sistema operativo.

Este documento es una guía paso a paso para el diseño e implementación de esa bodega. Se aplica la metodología Kimball explicada en las sesiones: selección del proceso de negocio, declaración del grano, identificación de dimensiones y hechos, y construcción de un modelo estrella con una tabla de hechos FACT_VENTAS y cinco dimensiones. Además, se ejecutó realmente el proceso ETL sobre un archivo de ventas crudas con errores intencionales, se validó la carga y se respondieron con SQL las preguntas del negocio.

Toda la implementación se realizó en un entorno cloud (máquina virtual Linux), porque el equipo personal del aprendiz no tiene los recursos necesarios para Oracle. Se usó Oracle Database Free en un contenedor Docker y CloudBeaver, la versión web oficial de DBeaver, para ejecutar los scripts y tomar las capturas. Los datos de Spring Valley son ficticios y fueron creados con fines académicos.

Contexto y problemática de Spring Valley

Spring Valley es una empresa (ficticia para efectos del caso) que comercializa bebidas y snacks saludables —aguas, jugos naturales, tés, bebidas funcionales y snacks— a través de cuatro sucursales en Bogotá, Medellín, Cali y Barranquilla, con ocho vendedores. El aprendiz fue contratado para guiar a la empresa en la consolidación de sus datos de ventas, de modo que pueda tomar decisiones con claridad, analizar su historia, hacer pronósticos e integrar procesos.

El problema central es que todas las consultas se hacían sobre el sistema OLTP (procesamiento de transacciones en línea). Un sistema OLTP está diseñado para registrar rápidamente operaciones diarias, como una factura, con tablas normalizadas y muchas escrituras pequeñas. Un sistema OLAP (procesamiento analítico en línea), en cambio, almacena datos históricos, integrados y desnormalizados para leer y resumir grandes volúmenes sin interrumpir la operación. Al ejecutar consultas analíticas pesadas sobre el OLTP, la facturación se bloqueó. La bodega de datos separa ambas cargas de trabajo: el OLTP sigue facturando y la bodega responde las preguntas de la dirección.

Además, la información de ventas llega con problemas de calidad: nombres con mayúsculas mezcladas y espacios, fechas en distintos formatos, el sexo del cliente y la forma de pago escritos de muchas maneras, y filas duplicadas. Por eso la bodega necesita un proceso ETL que limpie y estandarice los datos antes de cargarlos.

Planeación y línea de tiempo

La Tabla 1 presenta la planeación del proyecto. La duración es la propuesta para una implementación real en Spring Valley, organizada en siete semanas; la columna de estado indica qué se ejecutó en esta evidencia.

Tabla 1

Línea de tiempo del proyecto de bodega de datos

Fase	Actividad	Semana	Entregable	Estado en la evidencia
1	Análisis del problema	1	Diagnóstico OLTP vs. OLAP	Realizado
2	Levantamiento de requerimientos (negocio, compañía y técnicos)	1	Requerimientos documentados	Realizado
3	Identificación de fuentes de datos	2	Archivo plano de ventas 2023–2025	Realizado (datos ficticios)
4	Diseño dimensional (Kimball, grano, hechos y dimensiones)	2	Modelo estrella	Realizado
5	Preparación del entorno (Oracle, Docker, DBeaver)	3	Esquema SPRING_VALLEY y conexión	Realizado
6	Creación del staging	3	Tabla STG_VENTAS	Realizado

7	Proceso ETL: extracción y transformación	4	STG_VENTAS_LIMPIA	Realizado
8	Creación y carga de dimensiones	4	Cinco dimensiones cargadas	Realizado
9	Creación y carga de la tabla de hechos	5	FACT_VENTAS cargada	Realizado
10	Validación de la carga	5	Controles de calidad e integridad	Realizado
11	Consultas analíticas e interpretación	6	Respuestas a preguntas de negocio	Realizado
12	Documentación y entrega	7	Informe en PDF	Realizado

Requerimientos

Requerimientos del negocio

Son las preguntas que la dirección de Spring Valley necesita responder. Cada una se convirtió en una consulta SQL sobre la bodega (sección de consultas).

Tabla 2

Requerimientos del negocio

Código	Pregunta del negocio	Dimensiones y métricas
RN1	¿Cómo evolucionan las ventas por año?	DIM_TIEMPO; valor_total, cantidad
RN2	¿Qué productos y categorías venden más?	DIM_PRODUCTO; valor_total, cantidad
RN3	¿Cuánto vende cada sucursal y qué participación tiene?	DIM_SUCURSAL; valor_total
RN4	¿Qué vendedores tienen mejor desempeño?	DIM_VENDEDOR; valor_total, facturas
RN5	¿Quiénes son los clientes que más compran y cómo se comportan?	DIM_CLIENTE; valor_total, ticket
RN6	¿Cómo se distribuyen las ventas por forma de pago?	forma_pago; valor_total

Requerimientos de la compañía (gobierno de datos)

- Nombres estandarizados: tablas con prefijos STG_, DIM_ y FACT_; columnas en minúscula con guion bajo.
- Textos uniformes: nombres de personas, sucursales y ciudades en formato Nombre Propio (INITCAP); códigos y productos en mayúsculas (UPPER) y sin espacios sobrantes (TRIM).
- Fechas uniformes: todas con tipo DATE, sin importar el formato de origen.

- Catálogos controlados: sexo solo M o F; forma de pago solo Efectivo, Tarjeta crédito, Tarjeta débito o Transferencia.
- Información sin duplicados: una fila por línea de factura y una fila por cliente, producto, vendedor, sucursal y fecha.
- Integridad de datos: llaves primarias, llaves foráneas y restricciones CHECK en Oracle.
- Procesos medibles: conteos y totales comparados entre cada etapa del ETL.

Requerimientos técnicos

Tabla 3

Herramientas de hardware y software utilizadas

Recurso	**Detalle**	**Uso en el proyecto**
Entorno	Máquina virtual cloud, Ubuntu 24.04.4 LTS, x86_64	Servidor del laboratorio (el PC personal no tenía recursos)
CPU	4 vCPU Intel Xeon 2.80 GHz	Procesamiento de la base de datos
Memoria	15 GiB de RAM	Oracle usa ≈ 1,5 GB de SGA; queda margen para las herramientas
Almacenamiento	21 GB libres en disco	Imágenes de contenedores y datos
Contenedores	Docker 29.6.2	Aislar Oracle y CloudBeaver, como se indicó en las sesiones
Motor de base de datos	Oracle AI Database 26ai Free 23.26.3 (imagen gvenzl/oracle-free)	Bodega de datos, PDB FREEPDB1, puerto 1521
Cliente gráfico	CloudBeaver Community 26.2.1 (DBeaver web) en Chromium 141	Conexión, scripts SQL y capturas
Cliente complementario	Oracle SQL Developer 24.3.1	Diagrama del modelo estrella (pestaña Model)
Carga de archivos	Oracle SQLcl 26.3 (comando LOAD)	Extracción del archivo plano al staging
Lenguaje	SQL de Oracle	DDL, ETL, validación y consultas
Tiempo de respuesta esperado	Menos de 1 segundo por consulta analítica	Medido en CloudBeaver: entre 22 y 341 ms

Metodología Kimball

Se aplicó el enfoque de Ralph Kimball, de abajo hacia arriba (bottom-up): la bodega se construye a partir de las decisiones reales que el negocio necesita tomar, empezando por un proceso de negocio concreto, y no a partir de la tecnología. El proceso tiene cuatro pasos.

Tabla 4

Aplicación de los cuatro pasos de Kimball a Spring Valley

Paso	Decisión tomada	Justificación
1. Seleccionar el proceso de negocio	VENTAS	Es el área principal del caso y la fuente de las preguntas de la dirección.
2. Declarar el grano	Una fila de FACT_VENTAS = un producto vendido en una factura (una línea de factura).	Es el nivel más detallado disponible; permite sumar por factura, producto, cliente, vendedor, sucursal o fecha.
3. Identificar las dimensiones	Tiempo, cliente, producto, vendedor y sucursal.	Responden ¿cuándo?, ¿quién compra?, ¿qué?, ¿quién vende? y ¿dónde?
4. Identificar los hechos	cantidad, precio_unitario y valor_total.	Son medidas numéricas que se suman o promedian.

El diseño se desarrolló en los tres niveles explicados: conceptual (las cinco preguntas del negocio y sus dimensiones, comprensible para la gerencia), lógico (llaves, tipos de datos y relaciones de la Figura 1) y físico (sentencias CREATE TABLE ejecutadas en Oracle, Figuras 13 a 18).

Identificación de hechos y dimensiones

Tabla 5

Hechos (métricas) de FACT_VENTAS

Hecho	Tipo Oracle	Aditividad	Descripción
cantidad	NUMBER(6)	Aditiva	Unidades vendidas del producto en la línea
precio_unitario	NUMBER(12,2)	No aditiva (se promedia)	Precio de venta de cada unidad
valor_total	NUMBER(14,2)	Aditiva	cantidad × precio_unitario (validado con CHECK)

Además, la tabla de hechos guarda numero_factura como dimensión degenerada (un atributo de la transacción que no necesita tabla propia) y forma_pago como atributo controlado por una restricción CHECK. La forma de pago es un catálogo de solo cuatro valores, por lo que no se creó una dimensión aparte; así se respeta el modelo de cinco dimensiones visto en las sesiones.

Tabla 6

Dimensiones y la pregunta que responden

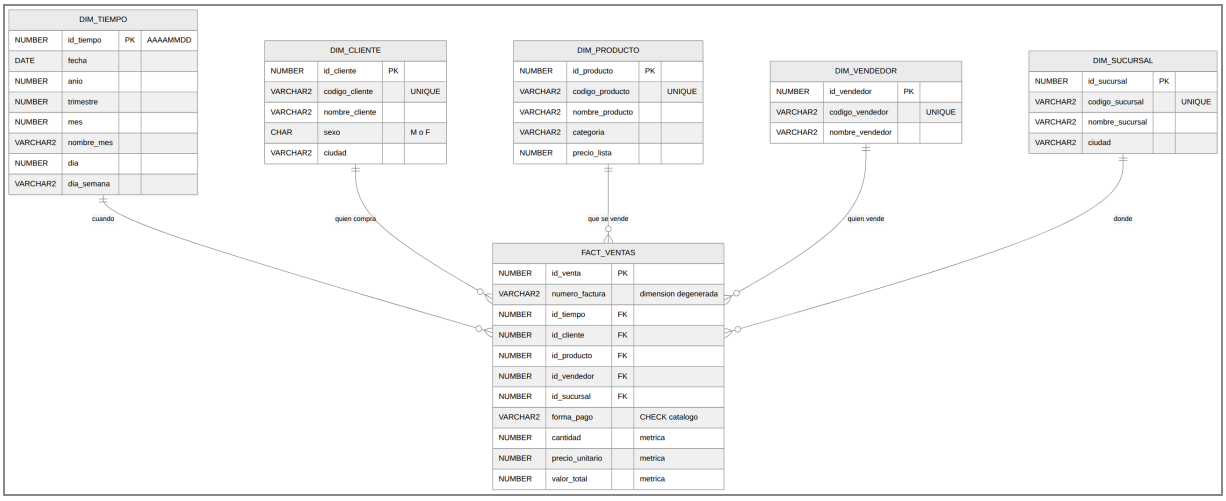
Dimensión	**Pregunta**	**Atributos principales**
DIM_TIEMPO	¿Cuándo?	fecha, año, trimestre, mes, nombre del mes, día, día de la semana
DIM_CLIENTE	¿Quién compra?	código, nombre, sexo, ciudad
DIM_PRODUCTO	¿Qué se vende?	código, nombre, categoría, precio de lista
DIM_VENDEDOR	¿Quién vende?	código, nombre
DIM_SUCURSAL	¿Dónde?	código, nombre, ciudad

Diseño del modelo estrella

El modelo estrella ubica la tabla de hechos en el centro y la rodea de las dimensiones. Cada dimensión tiene una llave primaria sustituta (numérica) y un código de negocio único; la tabla de hechos tiene una llave foránea hacia cada dimensión. La Figura 1 muestra el diseño lógico.

Figura 1

Diseño lógico del modelo estrella de ventas de Spring Valley



Nota. Elaboración propia. Diagrama elaborado en notación Mermaid a partir del diseño. Se observa FACT_VENTAS en el centro con sus métricas (cantidad, precio_unitario y valor_total), la dimensión degenerada numero_factura y cinco llaves foráneas hacia DIM_TIEMPO, DIM_CLIENTE, DIM_PRODUCTO, DIM_VENDEDOR y

DIM_SUCURSAL. Las relaciones son de uno a muchos: una fecha, un cliente o un producto aparecen en muchas ventas. Este diseño es la base de la implementación física.

Tabla 7

Definición de las tablas: columnas, tipos, llaves y restricciones

Tabla	**Columna**	**Tipo Oracle**	**Llave / restricción**
DIM_TIEMPO	id_tiempo	NUMBER(8)	PK (formato AAAAMMDD)
DIM_TIEMPO	fecha	DATE	NOT NULL, UNIQUE
DIM_TIEMPO	anio, trimestre, mes, dia	NUMBER	NOT NULL; CHECK trimestre 1–4 y mes 1–12
DIM_TIEMPO	nombre_mes, dia_semana	VARCHAR2(15)	NOT NULL
DIM_CLIENTE	id_cliente	NUMBER(6) IDENTITY	PK
DIM_CLIENTE	codigo_cliente	VARCHAR2(10)	NOT NULL, UNIQUE
DIM_CLIENTE	nombre_cliente, ciudad	VARCHAR2(100) / (50)	NOT NULL
DIM_CLIENTE	sexo	CHAR(1)	CHECK IN ('M','F')
DIM_PRODUCTO	id_producto	NUMBER(6) IDENTITY	PK
DIM_PRODUCTO	codigo_producto	VARCHAR2(10)	NOT NULL, UNIQUE
DIM_PRODUCTO	nombre_producto, categoria	VARCHAR2(100) / (50)	NOT NULL
DIM_PRODUCTO	precio_lista	NUMBER(12,2)	CHECK > 0
DIM_VENDEDOR	id_vendedor	NUMBER(6) IDENTITY	PK
DIM_VENDEDOR	codigo_vendedor, nombre_vendedor	VARCHAR2(10) / (100)	NOT NULL; código UNIQUE
DIM_SUCURSAL	id_sucursal	NUMBER(4) IDENTITY	PK
DIM_SUCURSAL	codigo_sucursal, nombre_sucursal, ciudad	VARCHAR2	NOT NULL; código UNIQUE
FACT_VENTAS	id_venta	NUMBER(10) IDENTITY	PK
FACT_VENTAS	numero_factura	VARCHAR2(15)	NOT NULL; UNIQUE con id_producto
FACT_VENTAS	id_tiempo, id_cliente, id_producto, id_vendedor, id_sucursal	NUMBER	FK hacia cada dimensión
FACT_VENTAS	forma_pago	VARCHAR2(20)	CHECK de 4 valores
FACT_VENTAS	cantidad / precio_unitario	NUMBER(6) / NUMBER(12,2)	CHECK > 0

FACT_VENTAS	valor_total	NUMBER(14,2)	CHECK = cantidad × precio_unitario

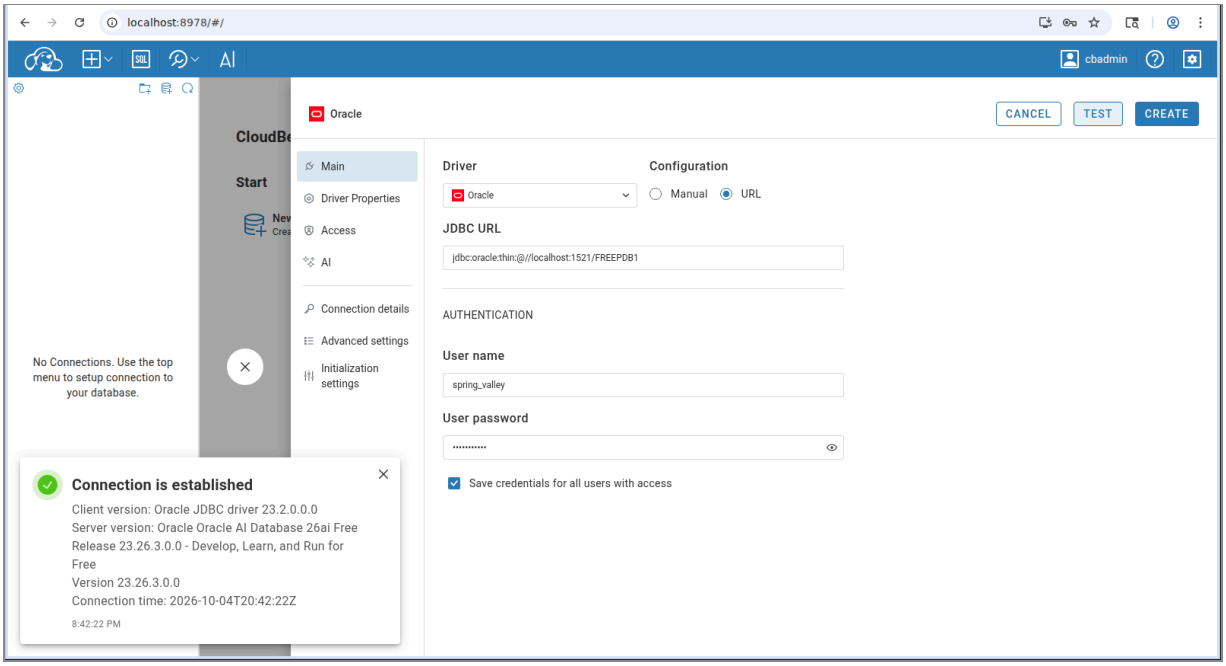
Herramientas de hardware y software

Las herramientas se resumieron en la Tabla 3. Se siguió el stack presentado en las sesiones: motor Oracle, contenedores Docker y DBeaver. Dos decisiones dependieron del entorno cloud y se documentan con transparencia:

- DBeaver de escritorio no se pudo descargar: los sitios dbeaver.io, dbeaver.com, GitHub y el repositorio PPA respondieron con un bloqueo de red (HTTP 403) del entorno. Por eso se usó CloudBeaver Community, la edición web oficial del mismo proyecto DBeaver, disponible como imagen de Docker (dbeaver/cloudbeaver). Su editor SQL, su navegador de objetos y su conexión JDBC a Oracle son los de DBeaver.
- CloudBeaver no incluye el editor de diagramas ER de DBeaver de escritorio. Para la evidencia gráfica de las relaciones se usó la pestaña Model de Oracle SQL Developer, que ya estaba instalado (Figura 20).
- Para cargar el archivo plano en el staging se usó el comando LOAD de Oracle SQLcl, porque la importación de archivos de CloudBeaver Community requiere subirlos desde el equipo cliente.

Figura 2

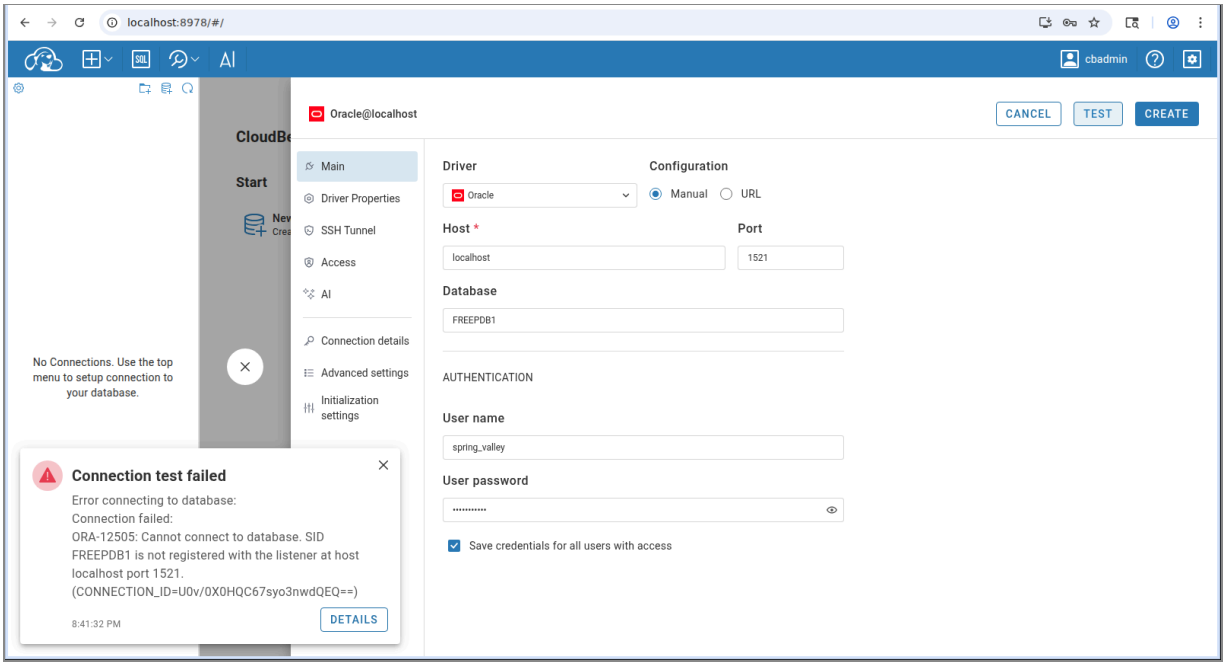
Conexión a Oracle desde DBeaver (CloudBeaver)



Nota. Elaboración propia. Se creó la conexión SPRING_VALLEY_DWH con el driver Oracle de DBeaver, la URL JDBC jdbc:oracle:thin:@//localhost:1521/FREEPDB1 y el usuario spring_valley. Al presionar TEST aparece el mensaje «Connection is established», con el driver Oracle JDBC 23.2 y el servidor Oracle AI Database 26ai Free 23.26.3. Esta conexión es el punto de partida de toda la implementación de la bodega.

Figura 3

Error real en el primer intento de conexión (ORA-12505)



Nota. Elaboración propia. En el primer intento se usó el modo de configuración Manual, que interpretó «FREEPDB1» como SID. Oracle respondió «ORA-12505: … SID FREEPDB1 is not registered with the listener», porque FREEPDB1 es un nombre de servicio de una base de datos conectable y no un SID. La solución fue cambiar al modo URL con la sintaxis de servicio //host:puerto/servicio, como muestra la Figura 2.

Preparación de datos

Como la guía indica que la información debe ser creada por el aprendiz, se generó un archivo plano de ventas 2023–2025 que simula una exportación del sistema OLTP de Spring Valley. Tiene 520 filas (255 facturas, de 1 a 3 productos por factura) y 17 columnas, con 20 clientes, 12 productos, 8 vendedores y 4 sucursales ficticios. Para practicar la limpieza enseñada en las sesiones, el archivo contiene intencionalmente:

- espacios adicionales al inicio y al final (286 filas con espacios en el nombre o la ciudad del cliente);

- mayúsculas y minúsculas mezcladas en nombres, ciudades, categorías y códigos (por ejemplo «c019» y «C019»);
- fechas en tres formatos: 2023-01-13, 06/01/2023 y 02-01-2023;
- el sexo escrito de 10 formas distintas (M, m, Masculino, MASCULINO, hombre, F, f, Femenino, FEMENINO, fem);
- la forma de pago escrita de 16 formas distintas (EFECTIVO, Efect., TC, T. Credito, transf, PSE, etc.);
- 10 filas duplicadas (la misma línea exportada dos veces).

El archivo original se conservó sin modificaciones (datos/ventas_crudas_spring_valley.csv, SHA-256 1a02eace…).

Figura 4

Datos crudos de ventas de Spring Valley



Nota. Elaboración propia. Se observa el archivo plano original abierto en el navegador. Ya en las primeras filas aparecen los problemas: la factura FV-10001 repetida, códigos en minúscula (c019, p001), el sexo como FEMENINO, fem, hombre o MASCULINO, ciudades como « medellín », fechas como 02-01-2023 y 2023-01-13, y formas de pago como TC, PSE o Efect.

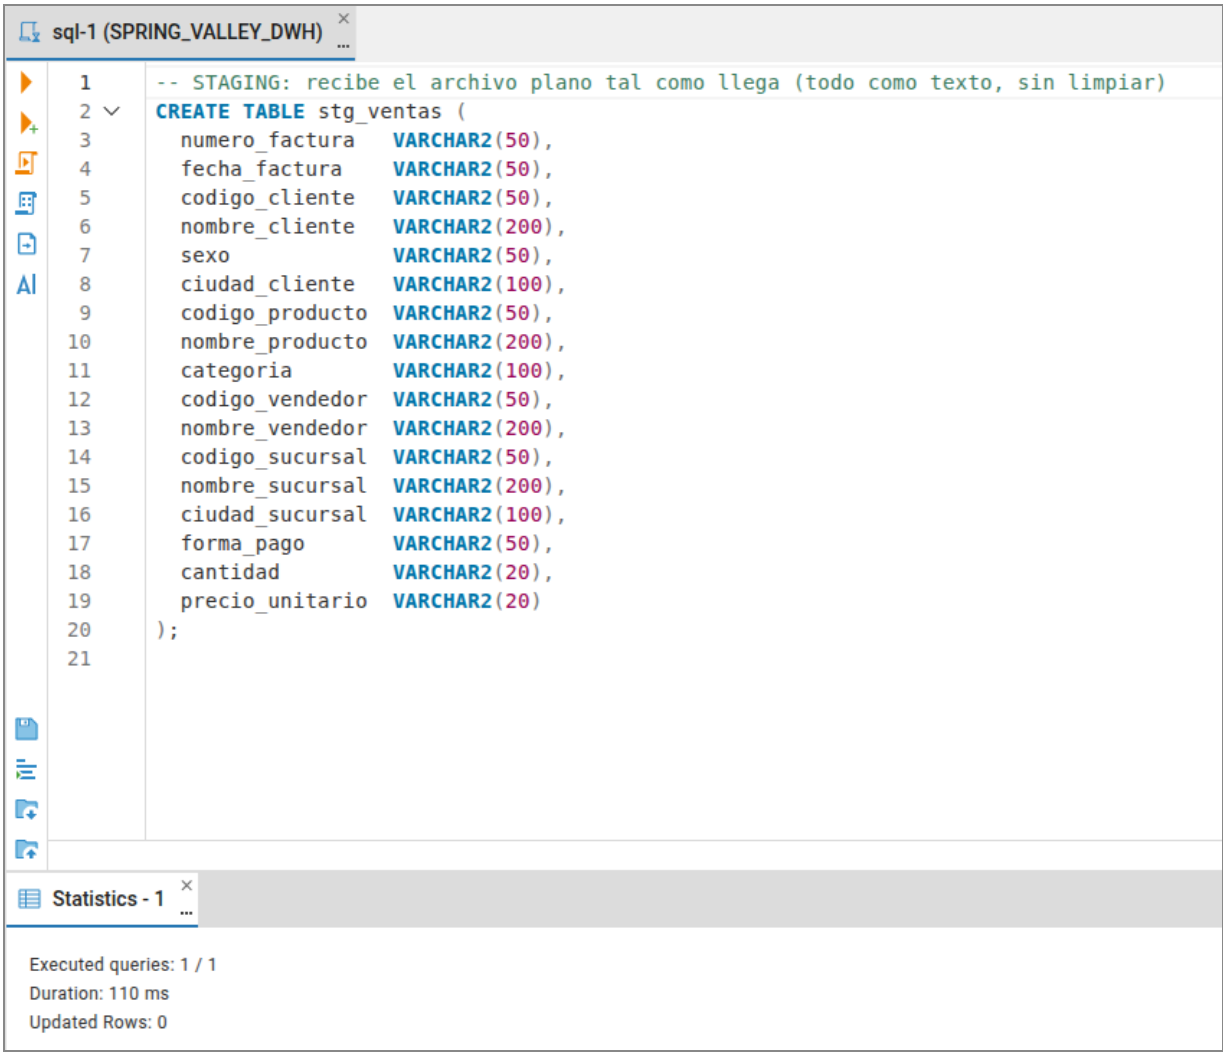
Estos datos no pueden cargarse así en la bodega, porque producirían categorías y conteos falsos.

Tabla staging

La tabla de staging es un área de trabajo que recibe los datos tal como llegan, antes de limpiarlos. Todas sus columnas son VARCHAR2, para que ningún valor sea rechazado por su formato y no se pierda información en la extracción.

Figura 5

Creación de la tabla STG_VENTAS en DBeaver



Nota. Elaboración propia. En el editor SQL de CloudBeaver se ejecutó CREATE TABLE stg_ventas con las 17 columnas del archivo, todas de tipo VARCHAR2. El panel Statistics muestra «Executed queries: 1 / 1» sin errores. Usar solo texto en el staging garantiza que la fecha 06/01/2023 o la cantidad «12» lleguen completas y que la conversión de tipos se haga después, de forma controlada, en la transformación.

Proceso ETL

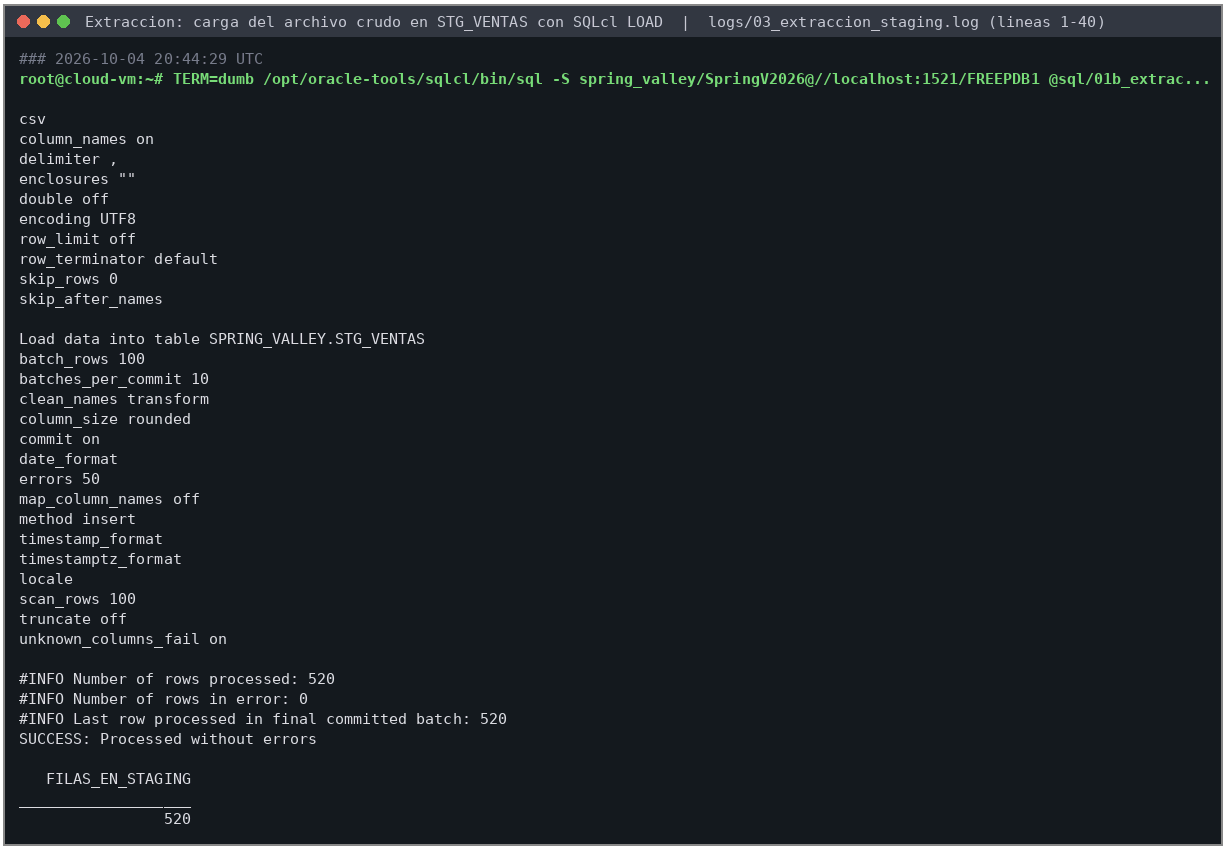
Extracción

La extracción llevó las 520 filas del archivo plano a STG_VENTAS sin alterar ningún valor, con el comando LOAD de SQLcl (formato CSV, lotes de 100 filas y confirmación automática).

```
set loadformat csv
load stg_ventas datos/ventas_crudas_spring_valley.csv
```

Figura 6

Extracción del archivo crudo hacia STG_VENTAS

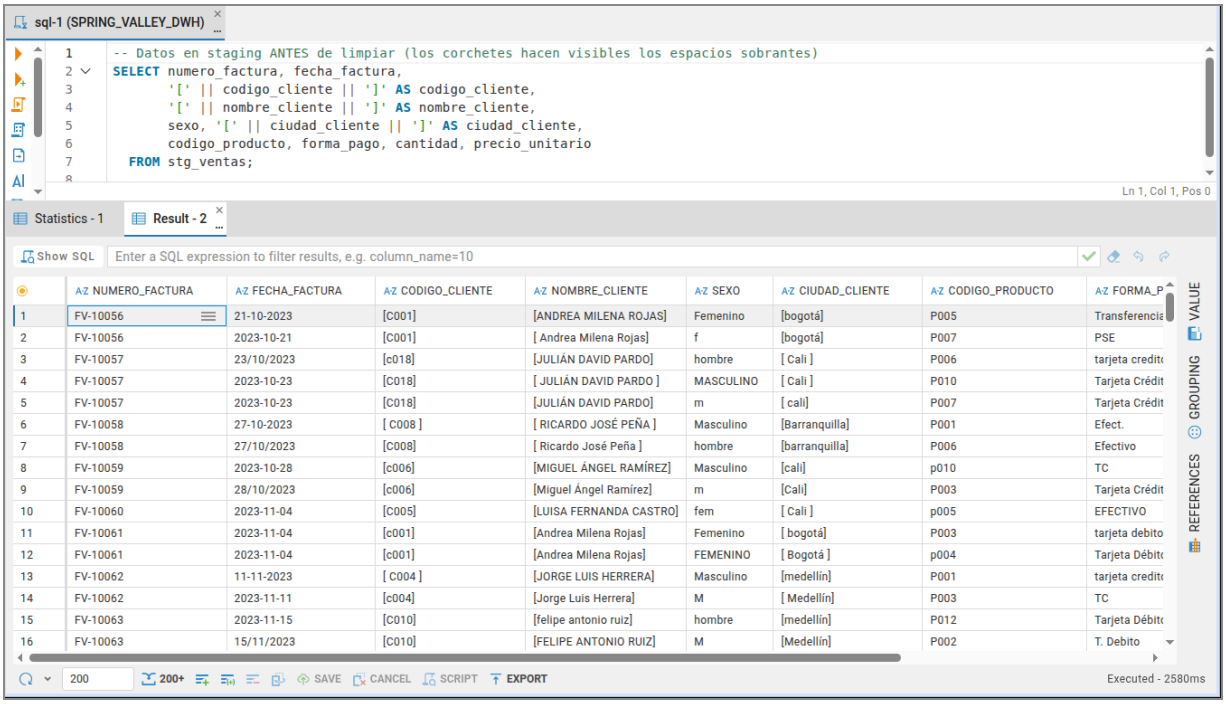


Nota. Elaboración propia. Imagen generada a partir del registro real de la terminal (logs/03_extraccion_staging.log). SQLcl informa «Number of rows processed: 520», «Number of rows in error: 0» y «SUCCESS: Processed without errors», y la consulta posterior

confirma 520 filas en staging. El conteo coincide con el archivo de origen, lo que demuestra una extracción completa.

Figura 7

Datos cargados en staging antes de limpiar



Nota. Elaboración propia. En DBeaver se consultó STG_VENTAS rodeando los textos con corchetes para hacer visibles los espacios. Se observan valores como «[RICARDO JOSÉ PEÑA]», «[C008]» y «[Cali]», el sexo como hombre, m o fem, fechas en formatos mezclados y formas de pago como Efect., TC o PSE. Esto confirma que el staging conservó el dato original, condición necesaria para poder auditar la limpieza.

Transformación

La transformación creó la tabla STG_VENTAS_LIMPIA aplicando las técnicas vistas en las sesiones:

Tabla 8

Técnicas de limpieza aplicadas

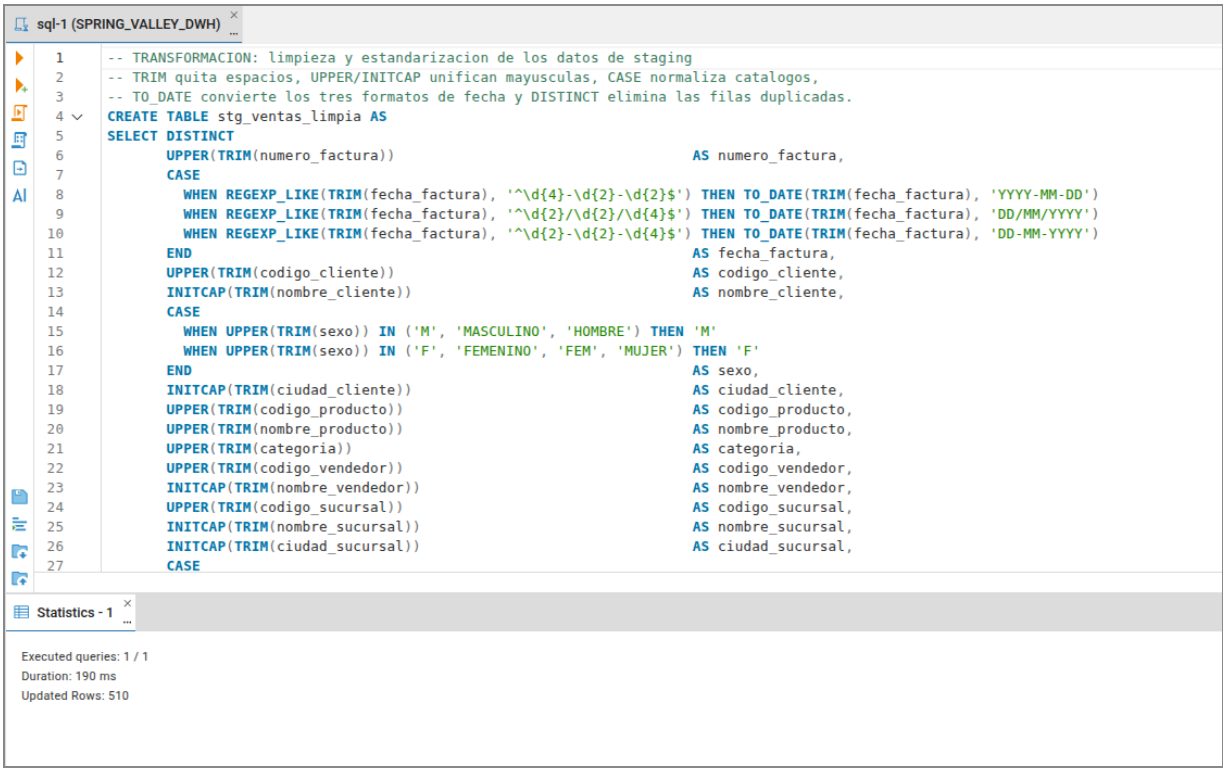
Problema	Técnica SQL	Ejemplo

Espacios sobrantes	TRIM	« medellín » → «medellín»
Mayúsculas en nombres y ciudades	INITCAP(TRIM(...))	«óscar iván londoño» → «Óscar Iván Londoño»
Códigos y productos	UPPER(TRIM(...))	« c016 » → «C016»
Sexo en varias formas	CASE … IN (...)	MASCULINO, hombre, m → M
Forma de pago en varias formas	CASE … LIKE	TC, T. Credito, tarjeta credito → Tarjeta crédito
Fechas en tres formatos	CASE + REGEXP_LIKE + TO_DATE	06/01/2023 y 2023-01-06 → DATE 06/01/2023
Números como texto	TO_NUMBER	«12» → 12
Filas duplicadas	SELECT DISTINCT	520 filas → 510 filas

```
CASE
  WHEN REGEXP_LIKE(TRIM(fecha_factura), '^\d{4}-\d{2}-\d{2}$') THEN TO_DATE(TRIM(fecha_factura),
'YYYY-MM-DD')
  WHEN REGEXP_LIKE(TRIM(fecha_factura), '^\d{2}/\d{2}/\d{4}$') THEN TO_DATE(TRIM(fecha_factura),
'DD/MM/YYYY')
  WHEN REGEXP_LIKE(TRIM(fecha_factura), '^\d{2}-\d{2}-\d{4}$') THEN TO_DATE(TRIM(fecha_factura),
'DD-MM-YYYY')
END AS fecha_factura
```

Figura 8

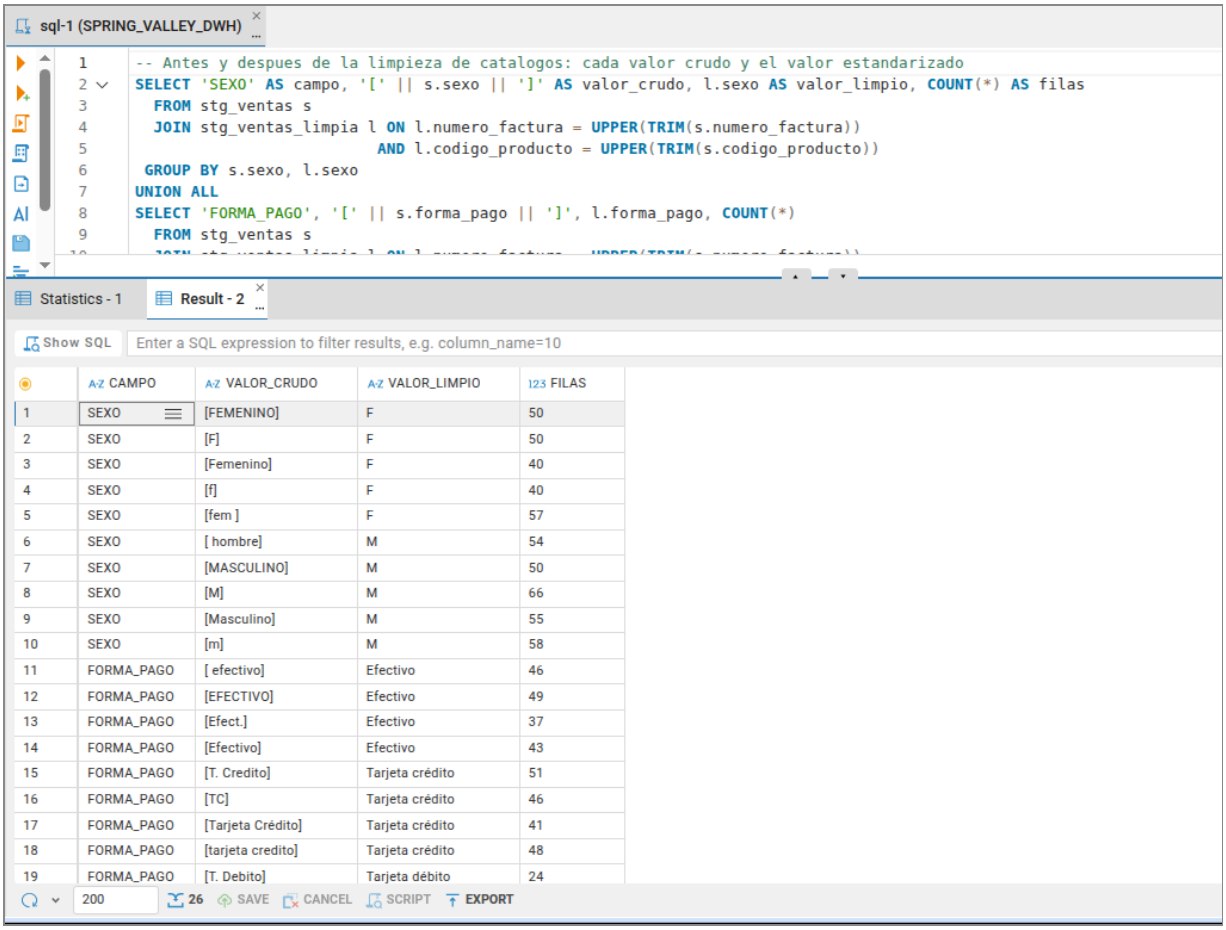
Ejecución de la transformación en DBeaver



Nota. Elaboración propia. Se ejecutó CREATE TABLE stg_ventas_limpia AS SELECT DISTINCT … con TRIM, UPPER, INITCAP, CASE, REGEXP_LIKE y TO_DATE. El panel Statistics indica «Updated Rows: 510»: de las 520 filas crudas quedaron 510, porque DISTINCT eliminó los 10 duplicados. Este paso convierte datos inconsistentes en información confiable antes de tocar la bodega.

Figura 9

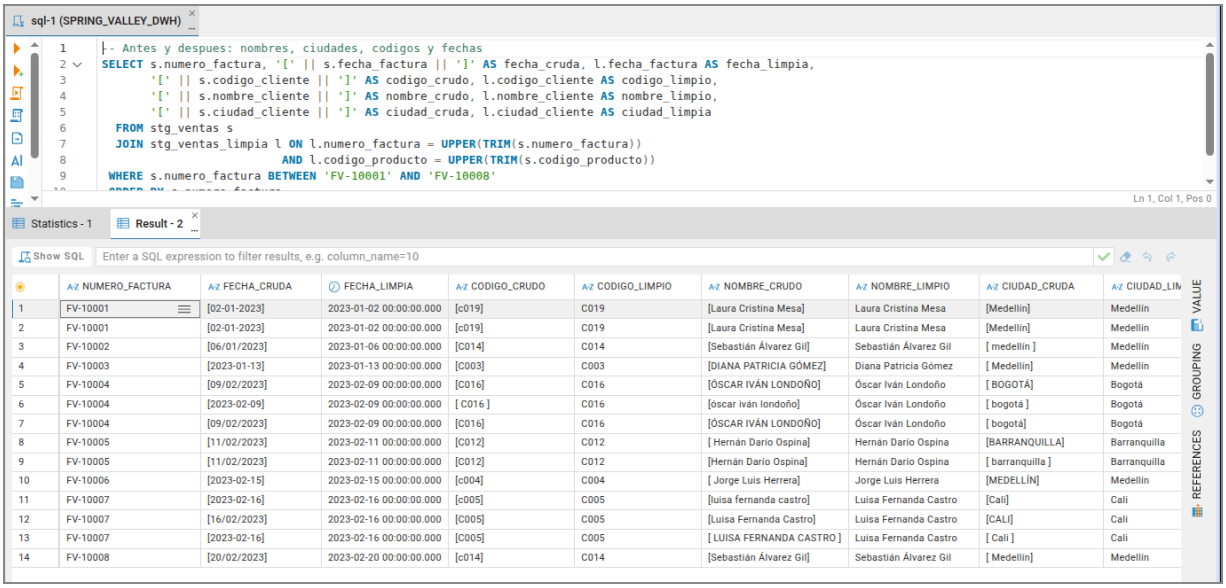
Antes y después: sexo y forma de pago



Nota. Elaboración propia. La consulta une STG_VENTAS con STG_VENTAS_LIMPIA y agrupa cada valor crudo con su valor estandarizado. Las 10 variantes de sexo ([FEMENINO], [f], [fem], [hombre], [MASCULINO], [m]…) quedaron reducidas a F y M, y las 16 variantes de forma de pago a cuatro valores (Efectivo, Tarjeta crédito, Tarjeta débito y Transferencia). Sin este paso, el análisis por forma de pago mostraría 16 categorías en lugar de cuatro.

Figura 10

Antes y después: nombres, códigos, ciudades y fechas



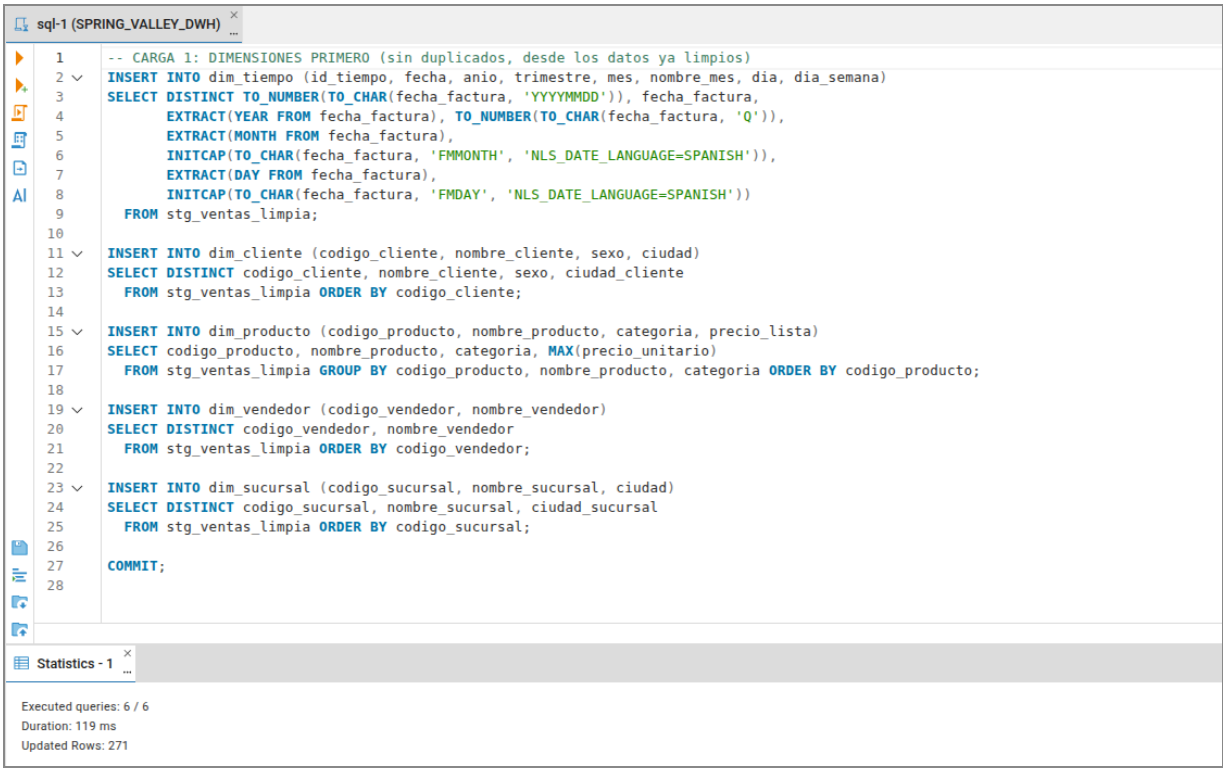
Nota. Elaboración propia. Para las facturas FV-10001 a FV-10008 se comparan los valores crudos (entre corchetes) con los limpios. [09/02/2023] y [2023-02-09] se convirtieron en la misma fecha 2023-02-09; [C016] y [c016] en C016; [ÓSCAR IVÁN LONDOÑO] y [óscar iván londoño] en Óscar Iván Londoño; y [BOGOTÁ] en Bogotá. Esto garantiza que un mismo cliente o una misma fecha se registren una sola vez en las dimensiones.

Carga

Se respetó el orden indicado por los instructores: primero las dimensiones y después la tabla de hechos, porque cada venta debe apuntar a llaves de dimensión que ya existan.

Figura 11

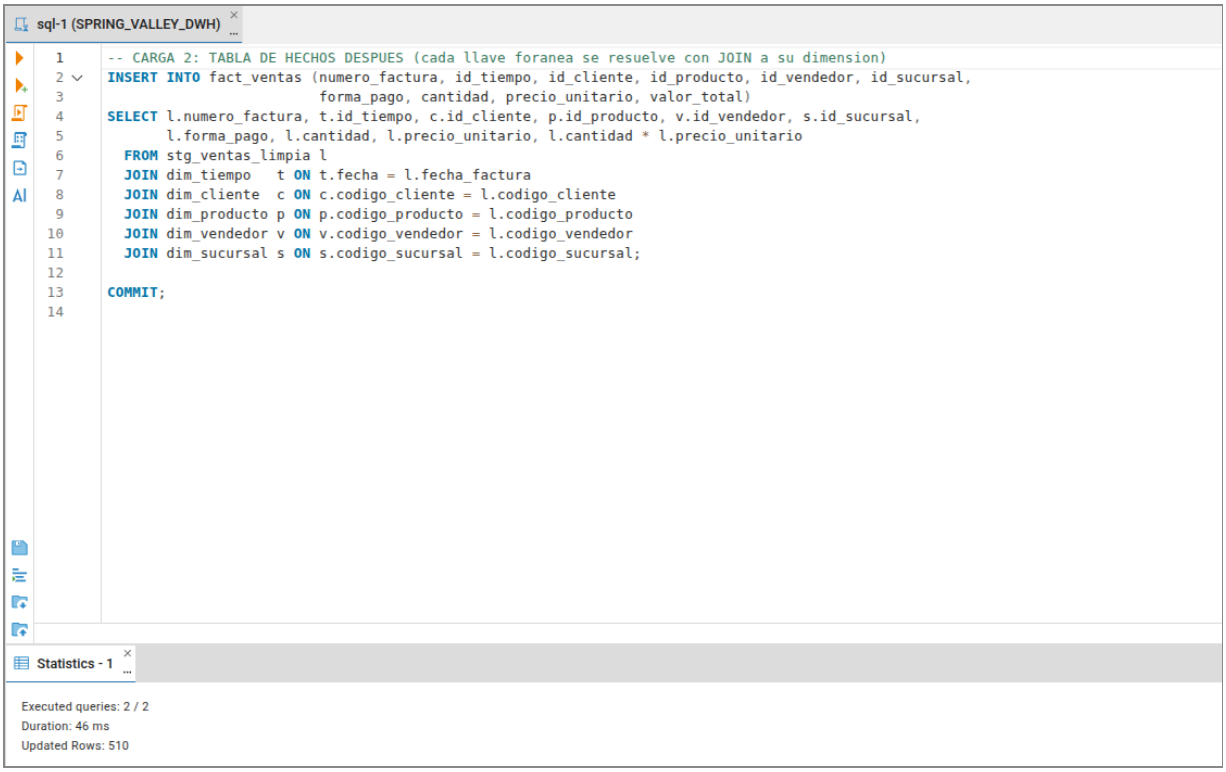
Carga de las dimensiones (primero)



Nota. Elaboración propia. Con INSERT INTO … SELECT DISTINCT desde STG_VENTAS_LIMPIA se poblaron las cinco dimensiones sin duplicados. DIM_TIEMPO calcula año, trimestre, mes, nombre del mes y día de la semana en español con EXTRACT y TO_CHAR. El resultado es «Executed queries: 6 / 6» y «Updated Rows: 271» (227 fechas, 20 clientes, 12 productos, 8 vendedores y 4 sucursales), confirmados con COMMIT.

Figura 12

Carga de la tabla de hechos (después)



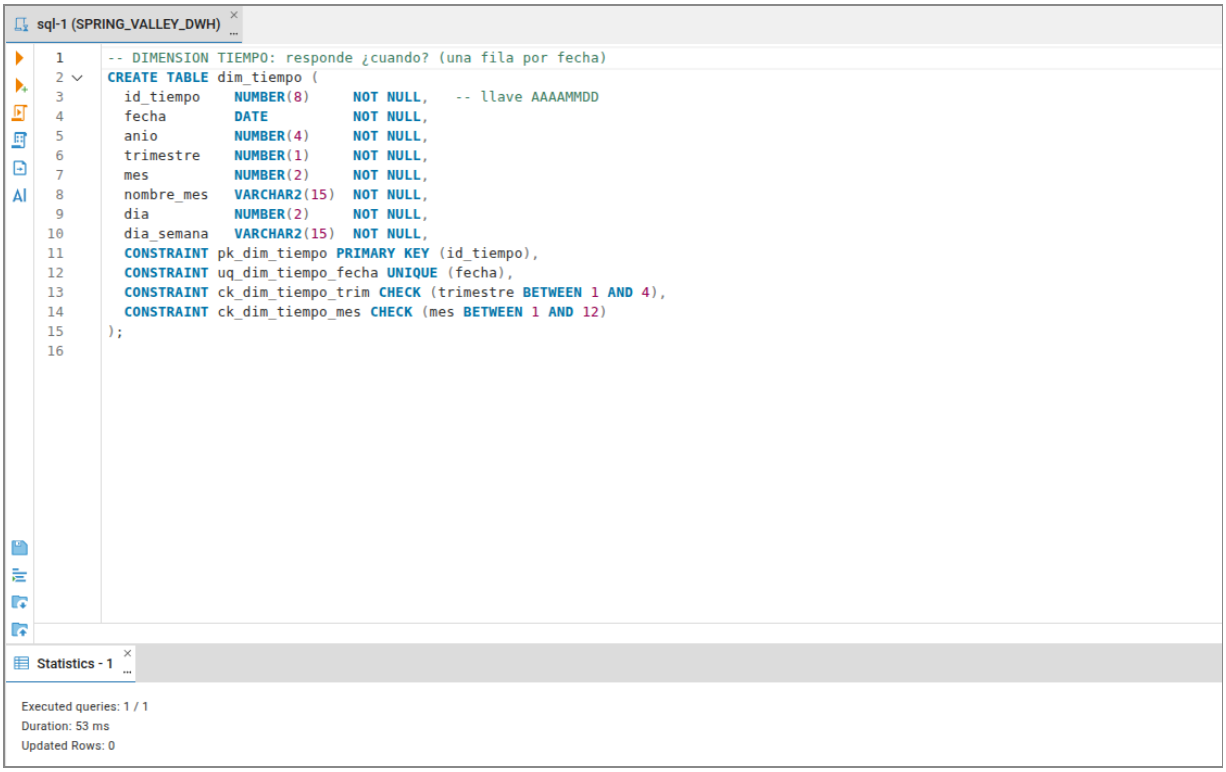
Nota. Elaboración propia. La carga de FACT_VENTAS resuelve cada llave foránea con un JOIN entre el staging limpio y su dimensión (por fecha y por código de cliente, producto, vendedor y sucursal) y calcula valor_total = cantidad × precio_unitario. Se insertaron 510 filas («Updated Rows: 510»), una por cada línea de factura limpia, lo que cumple el grano declarado.

Implementación del modelo

Las seis tablas del modelo estrella se crearon en DBeaver antes de la carga. Las figuras siguientes muestran cada sentencia ejecutada.

Figura 13

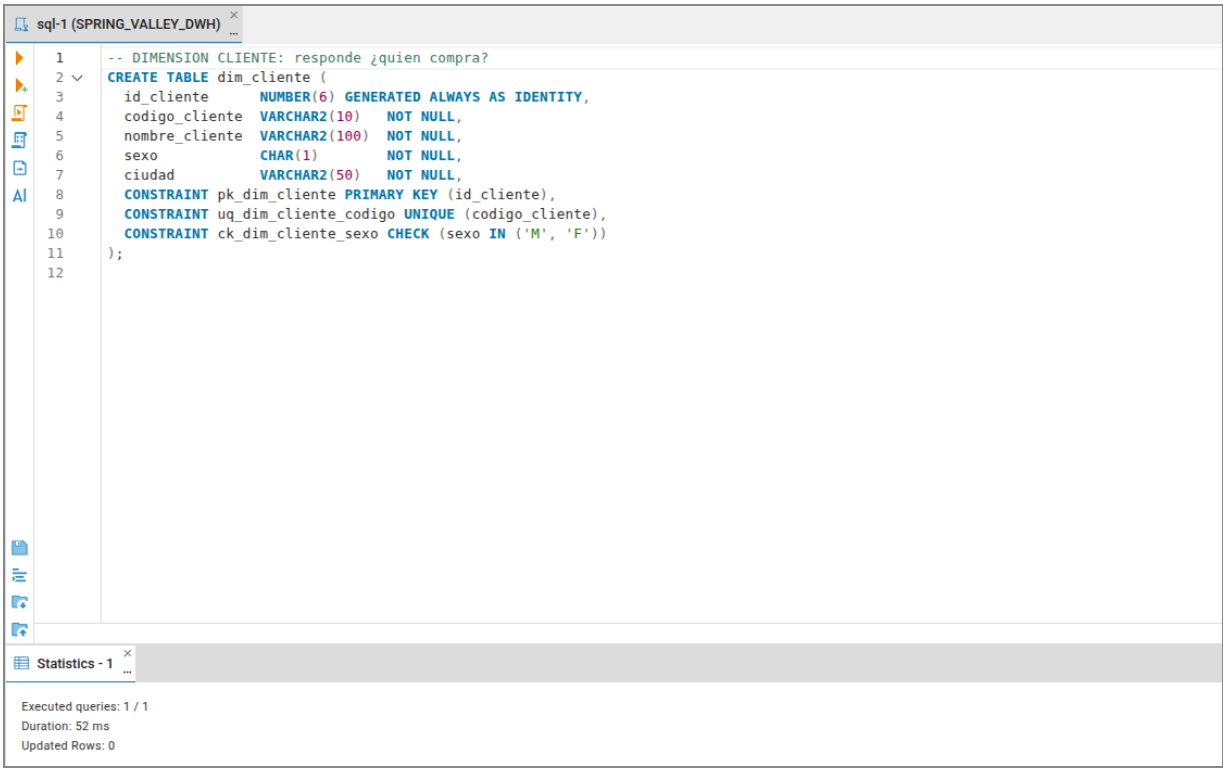
Creación de DIM_TIEMPO



Nota. Elaboración propia. CREATE TABLE dim_tiempo define id_tiempo NUMBER(8) como llave primaria en formato AAAAMMDD, la fecha única y los atributos de calendario, con restricciones CHECK para trimestre (1 a 4) y mes (1 a 12). Esta dimensión permite analizar las ventas por año, trimestre y mes.

Figura 14

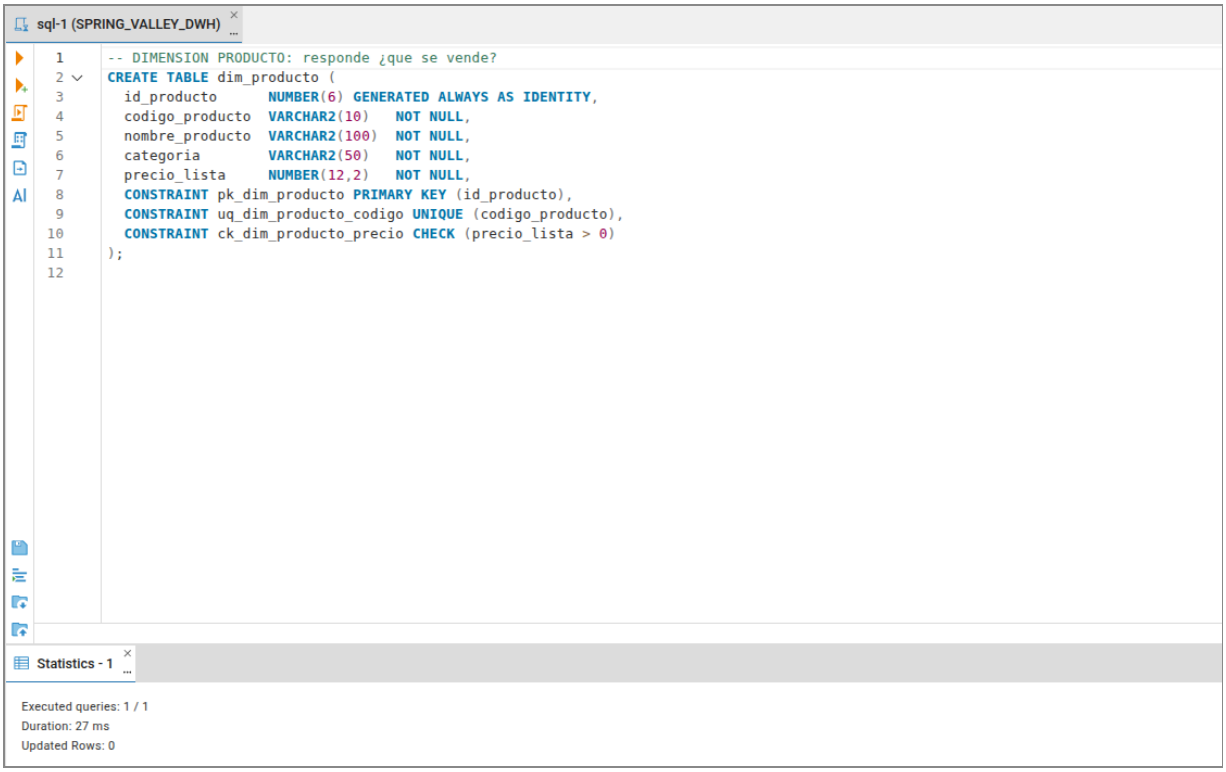
Creación de DIM_CLIENTE



Nota. Elaboración propia. La dimensión de clientes usa una llave sustituta id_cliente generada automáticamente (IDENTITY), el código de negocio como UNIQUE y la restricción CHECK sexo IN ('M','F'), que obliga a que solo entren valores ya estandarizados. Responde a la pregunta ¿quién compra?

Figura 15

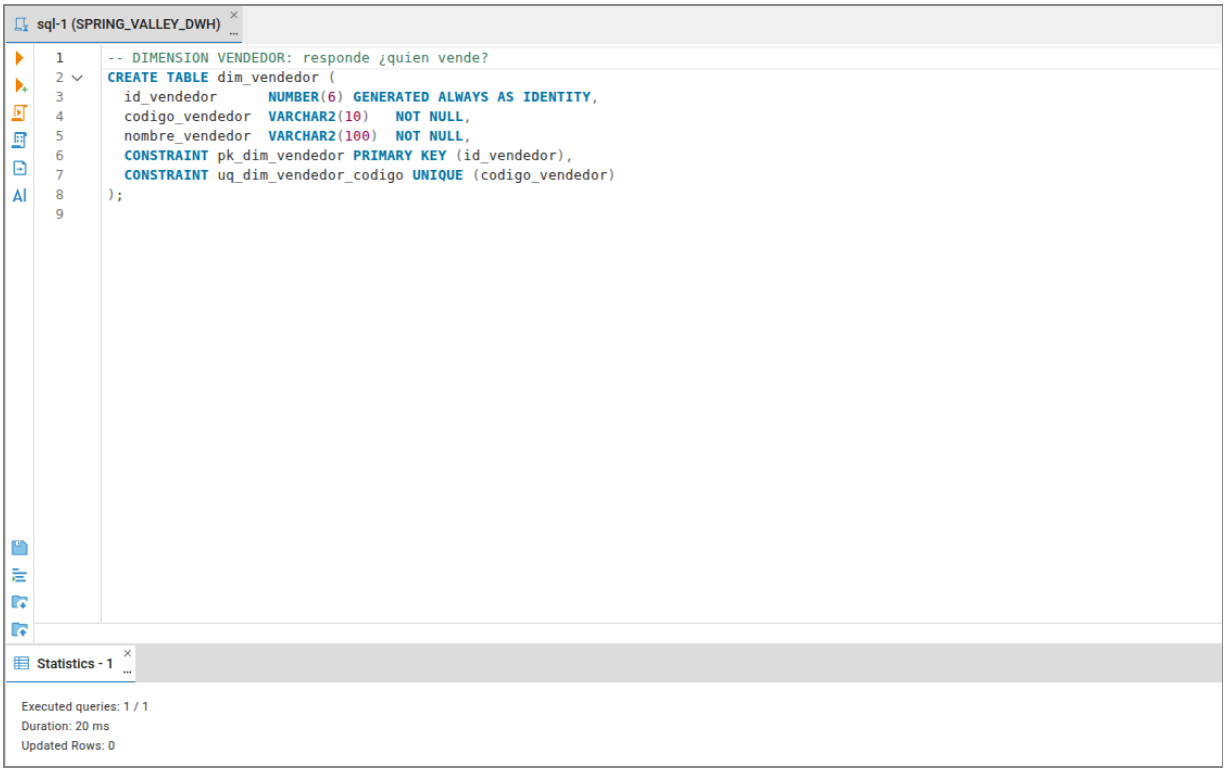
Creación de DIM_PRODUCTO



Nota. Elaboración propia. Se define el producto con código único, nombre, categoría y precio de lista NUMBER(12,2) con CHECK > 0. La categoría permite agrupar las ventas por línea de negocio (aguas, jugos, tés, bebidas funcionales y snacks).

Figura 16

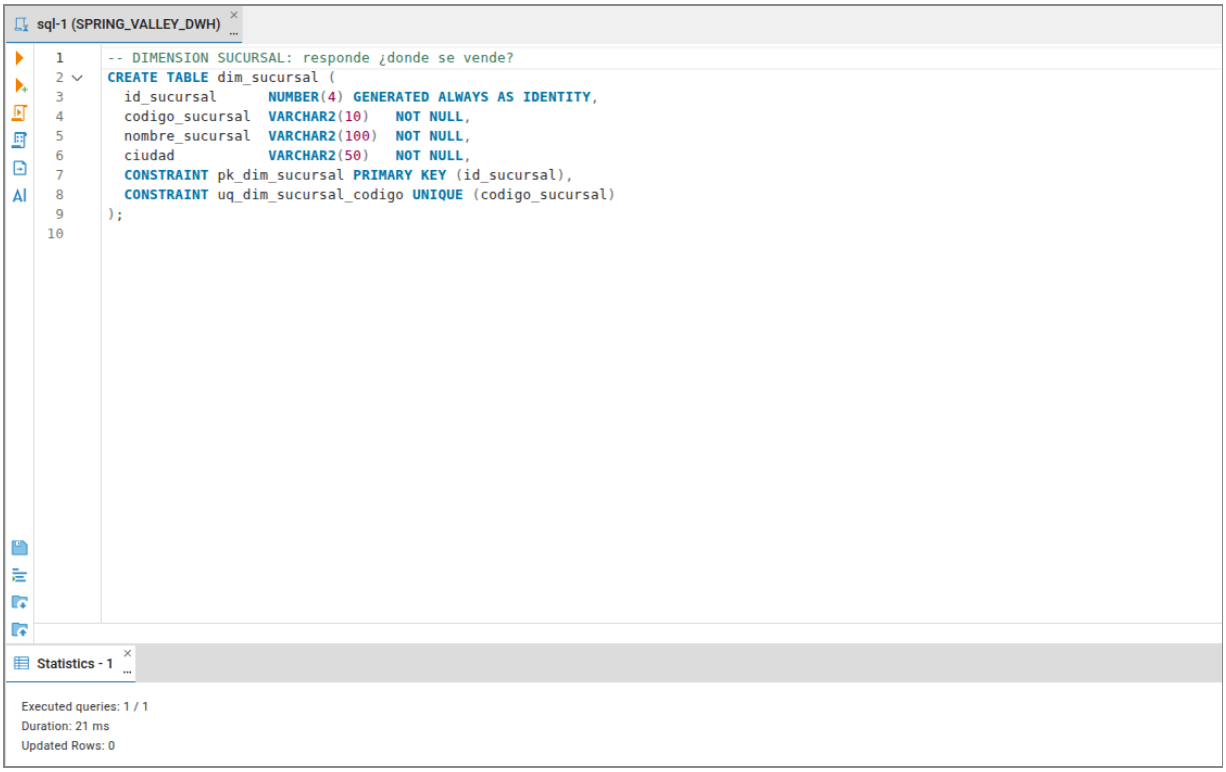
Creación de DIM_VENDEDOR



Nota. Elaboración propia. La dimensión de vendedores contiene la llave sustituta, el código único y el nombre. Es la base del ranking de desempeño comercial.

Figura 17

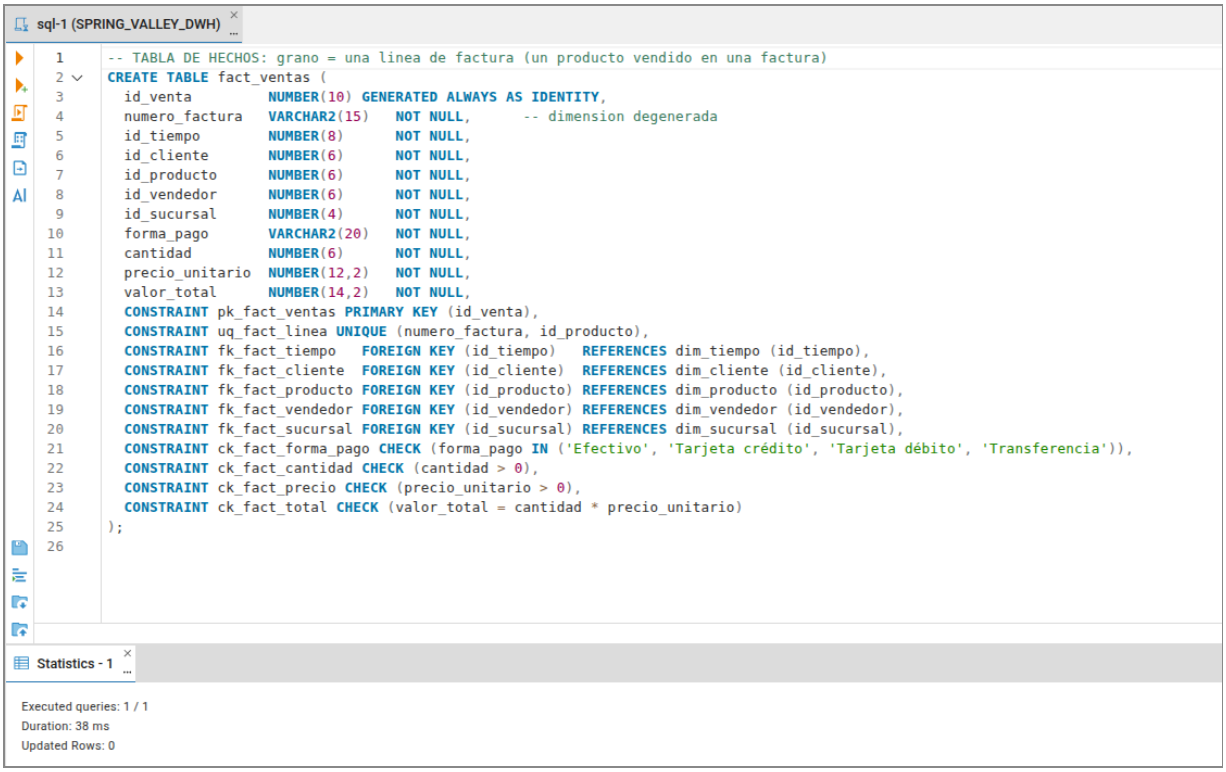
Creación de DIM_SUCURSAL



Nota. Elaboración propia. La dimensión de sucursales guarda código, nombre y ciudad, y responde a la pregunta ¿dónde se vende? En todas las sentencias el panel Statistics muestra «Executed queries: 1 / 1» sin errores.

Figura 18

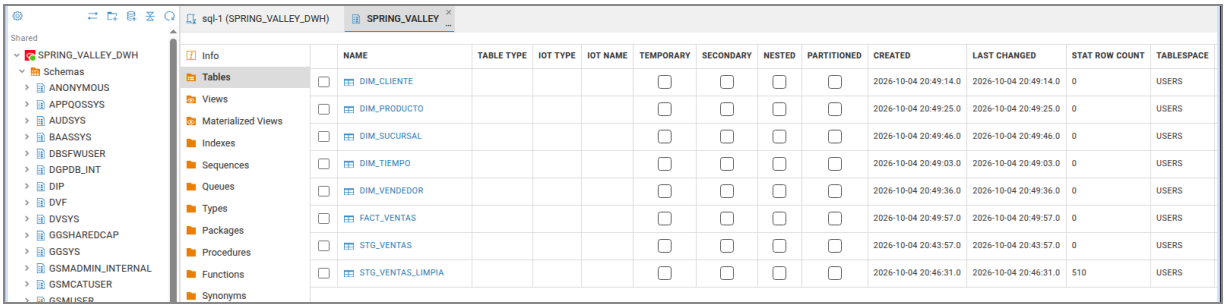
Creación de FACT_VENTAS



Nota. Elaboración propia. La tabla de hechos contiene id_venta como llave primaria, numero_factura como dimensión degenerada, cinco llaves foráneas (FK_FACT_TIEMPO, FK_FACT_CLIENTE, FK_FACT_PRODUCTO, FK_FACT_VENDEDOR y FK_FACT_SUCURSAL) y las métricas. Las restricciones CHECK validan el catálogo de forma de pago, que cantidad y precio sean positivos y que valor_total sea exactamente cantidad × precio_unitario; la restricción UNIQUE (numero_factura, id_producto) impide duplicar una línea de factura.

Figura 19

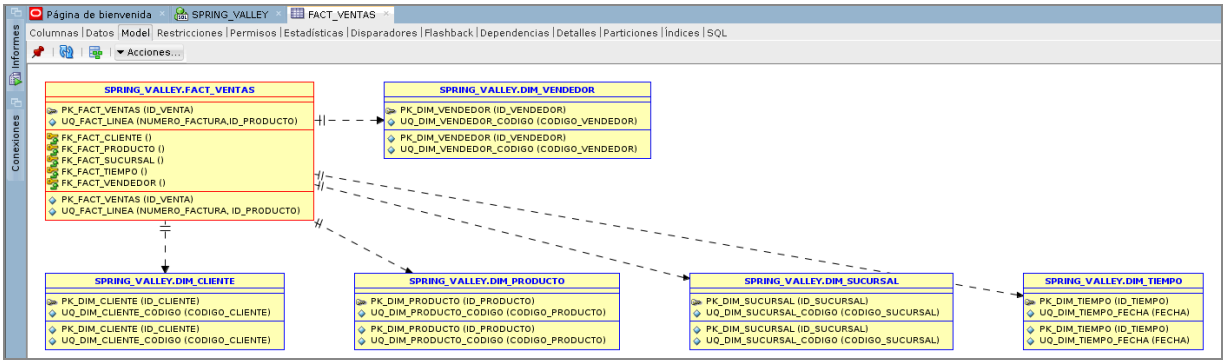
Tablas del esquema SPRING_VALLEY en DBeaver



Nota. Elaboración propia. En el navegador de objetos de CloudBeaver, la pestaña Tables del esquema SPRING_VALLEY lista las ocho tablas: las cinco dimensiones, FACT_VENTAS y las dos tablas de staging (STG_VENTAS y STG_VENTAS_LIMPIA), todas en el tablespace USERS. Esto confirma la estructura física completa de la bodega.

Figura 20

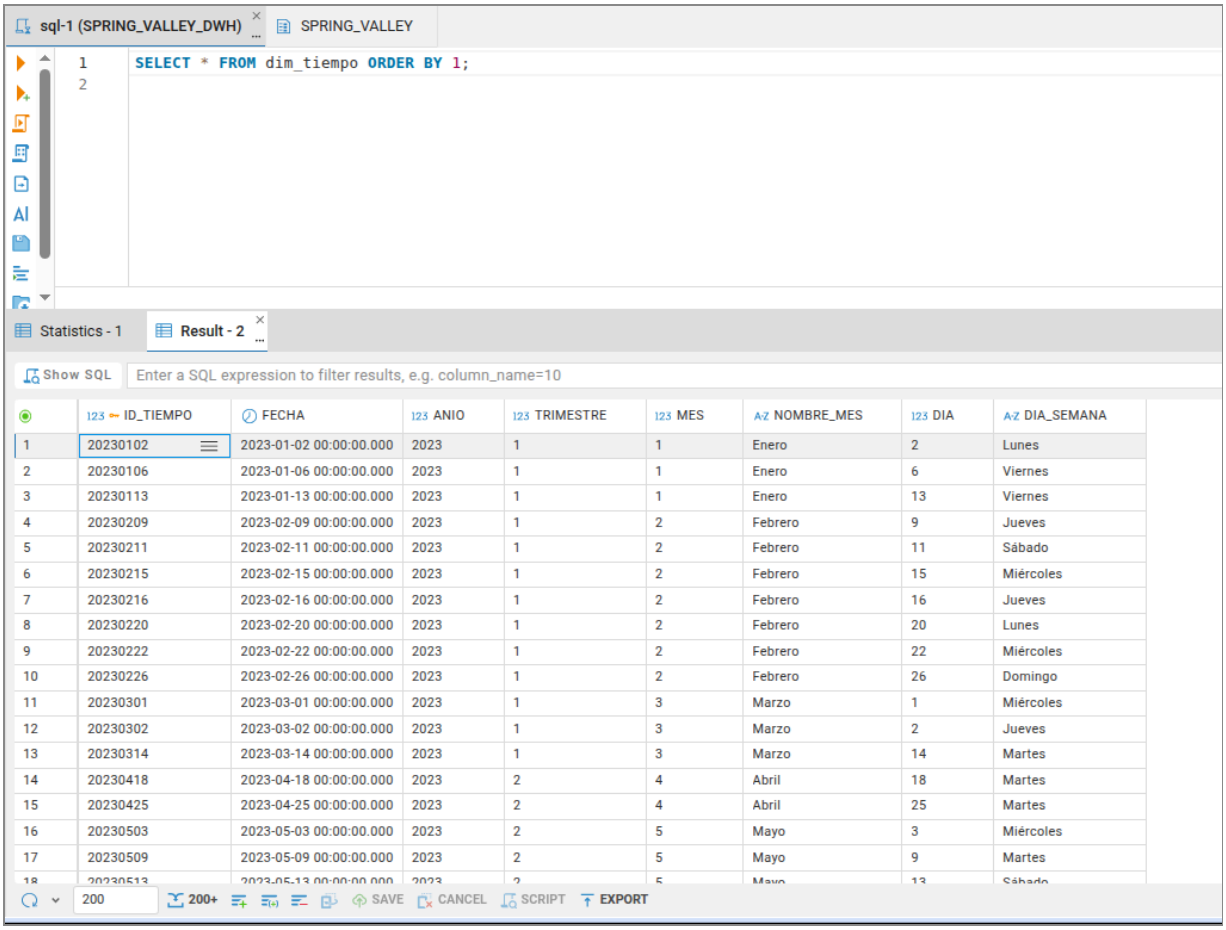
Esquema estrella generado desde la base de datos



Nota. Elaboración propia. La pestaña Model de FACT_VENTAS en Oracle SQL Developer lee las llaves foráneas reales de Oracle y dibuja la estrella: FACT_VENTAS (en rojo) se relaciona con DIM_VENDEDOR, DIM_CLIENTE, DIM_PRODUCTO, DIM_SUCURSAL y DIM_TIEMPO. Se usó SQL Developer porque CloudBeaver Community no trae editor de diagramas ER. El diagrama coincide con el diseño de la Figura 1, lo que comprueba que el modelo quedó implementado tal como se diseñó.

Figura 21

DIM_TIEMPO cargada

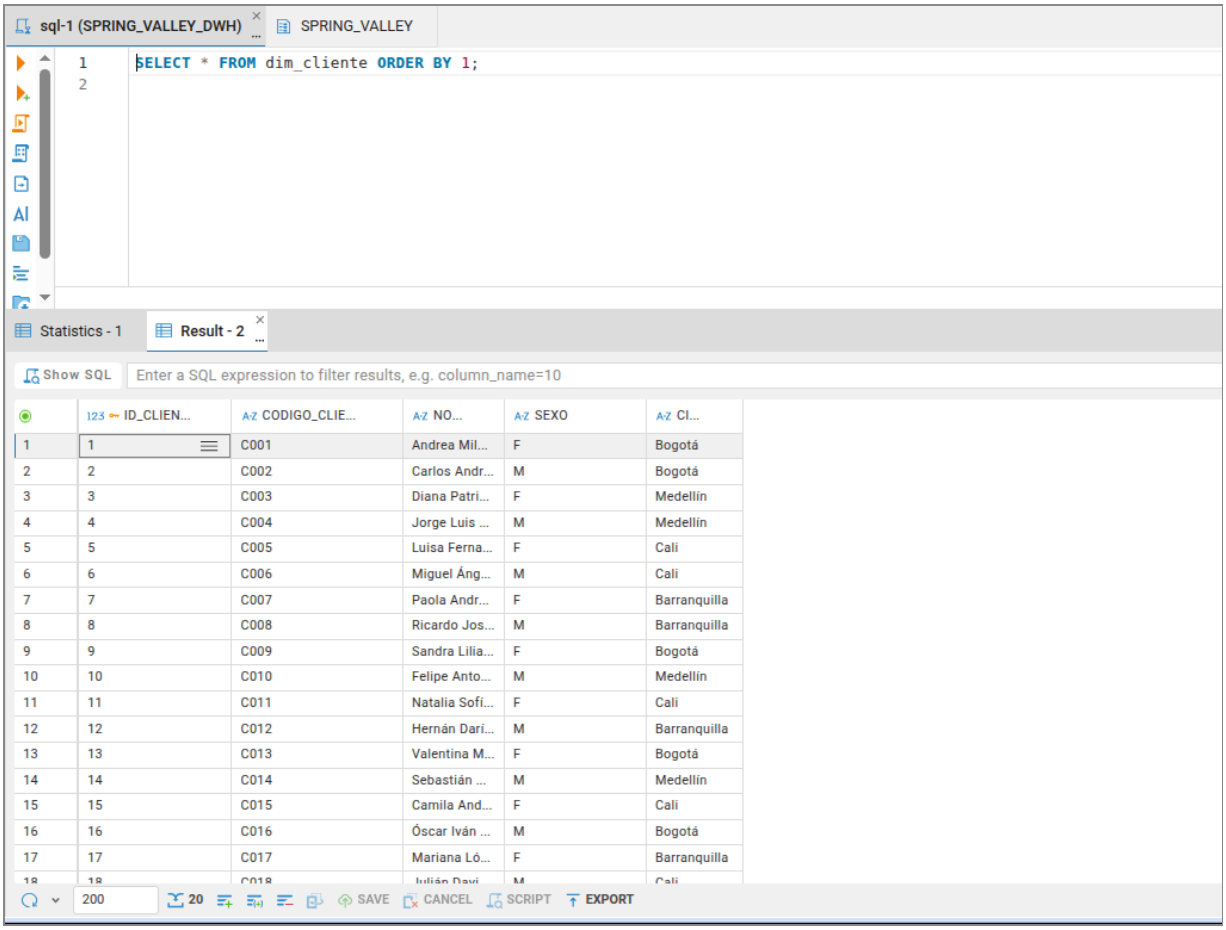


	ID_TIEMPO	FECHA	ANIO	TRIMESTRE	MES	NOMBRE_MES	DIA	DIA_SEMANA
1	20230102	2023-01-02 00:00:00.000	2023	1	1	Enero	2	Lunes
2	20230106	2023-01-06 00:00:00.000	2023	1	1	Enero	6	Viernes
3	20230113	2023-01-13 00:00:00.000	2023	1	1	Enero	13	Viernes
4	20230209	2023-02-09 00:00:00.000	2023	1	2	Febrero	9	Jueves
5	20230211	2023-02-11 00:00:00.000	2023	1	2	Febrero	11	Sábado
6	20230215	2023-02-15 00:00:00.000	2023	1	2	Febrero	15	Miércoles
7	20230216	2023-02-16 00:00:00.000	2023	1	2	Febrero	16	Jueves
8	20230220	2023-02-20 00:00:00.000	2023	1	2	Febrero	20	Lunes
9	20230222	2023-02-22 00:00:00.000	2023	1	2	Febrero	22	Miércoles
10	20230226	2023-02-26 00:00:00.000	2023	1	2	Febrero	26	Domingo
11	20230301	2023-03-01 00:00:00.000	2023	1	3	Marzo	1	Miércoles
12	20230302	2023-03-02 00:00:00.000	2023	1	3	Marzo	2	Jueves
13	20230314	2023-03-14 00:00:00.000	2023	1	3	Marzo	14	Martes
14	20230418	2023-04-18 00:00:00.000	2023	2	4	Abril	18	Martes
15	20230425	2023-04-25 00:00:00.000	2023	2	4	Abril	25	Martes
16	20230503	2023-05-03 00:00:00.000	2023	2	5	Mayo	3	Miércoles
17	20230509	2023-05-09 00:00:00.000	2023	2	5	Mayo	9	Martes

Nota. Elaboración propia. La consulta SELECT * FROM dim_tiempo muestra las fechas con su llave AAAAMMDD, el año, el trimestre, el mes, el nombre del mes y el día de la semana en español (Enero, Lunes, Viernes…). Al tener el calendario precalculado, las consultas por período no necesitan funciones de fecha.

Figura 22

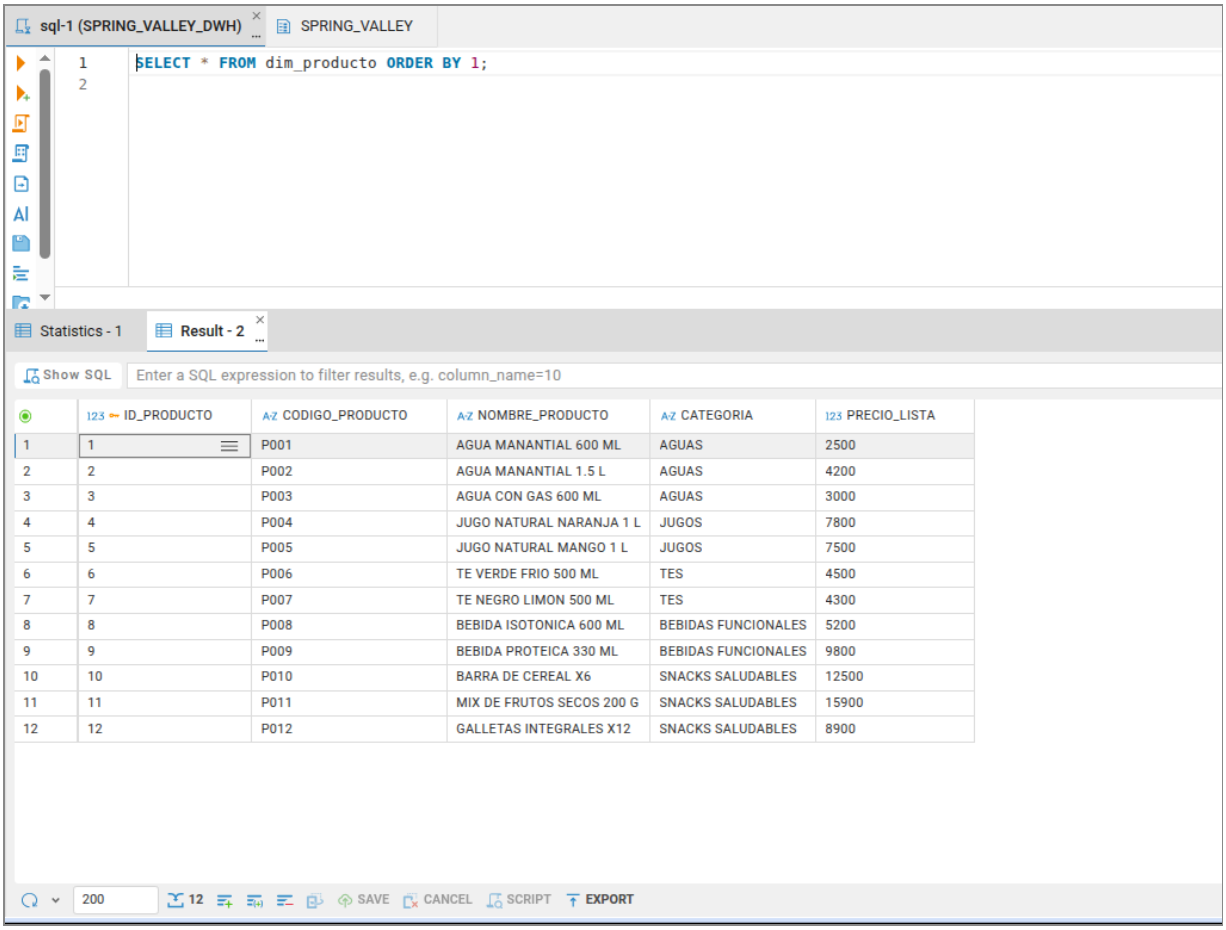
DIM_CLIENTE cargada



Nota. Elaboración propia. La dimensión contiene 20 clientes, uno por código, con nombres en formato Nombre Propio, el sexo como M o F y la ciudad estandarizada. Aunque en el archivo crudo el mismo cliente aparecía escrito de varias formas, aquí existe una sola fila por cliente.

Figura 23

DIM_PRODUCTO cargada

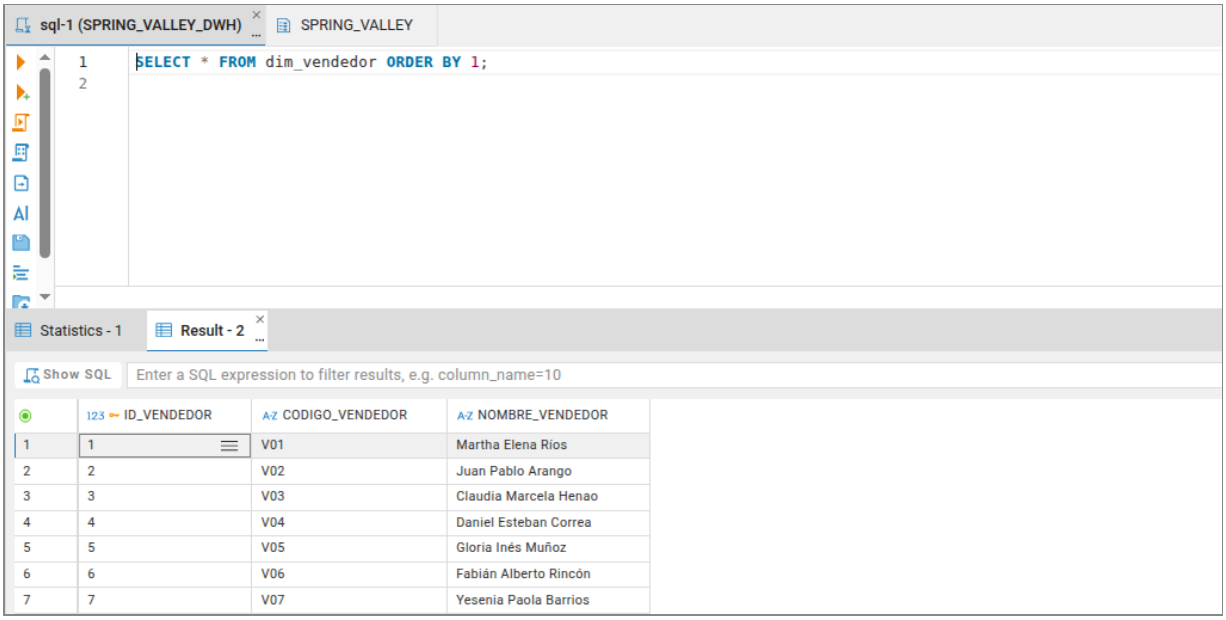


	ID_PRODUCTO	CODIGO_PRODUCTO	NOMBRE_PRODUCTO	CATEGORIA	PRECIO_LISTA
1	1	P001	AGUA MANANTIAL 600 ML	AGUAS	2500
2	2	P002	AGUA MANANTIAL 1.5 L	AGUAS	4200
3	3	P003	AGUA CON GAS 600 ML	AGUAS	3000
4	4	P004	JUGO NATURAL NARANJA 1 L	JUGOS	7800
5	5	P005	JUGO NATURAL MANGO 1 L	JUGOS	7500
6	6	P006	TE VERDE FRIO 500 ML	TES	4500
7	7	P007	TE NEGRO LIMON 500 ML	TES	4300
8	8	P008	BEBIDA ISOTONICA 600 ML	BEBIDAS FUNCIONALES	5200
9	9	P009	BEBIDA PROTEICA 330 ML	BEBIDAS FUNCIONALES	9800
10	10	P010	BARRA DE CEREAL X6	SNACKS SALUDABLES	12500
11	11	P011	MIX DE FRUTOS SECOS 200 G	SNACKS SALUDABLES	15900
12	12	P012	GALLETAS INTEGRALES X12	SNACKS SALUDABLES	8900

Nota. Elaboración propia. Se observan los 12 productos (P001 a P012) con su categoría en mayúsculas y su precio de lista, sin espacios ni variaciones de escritura.

Figura 24

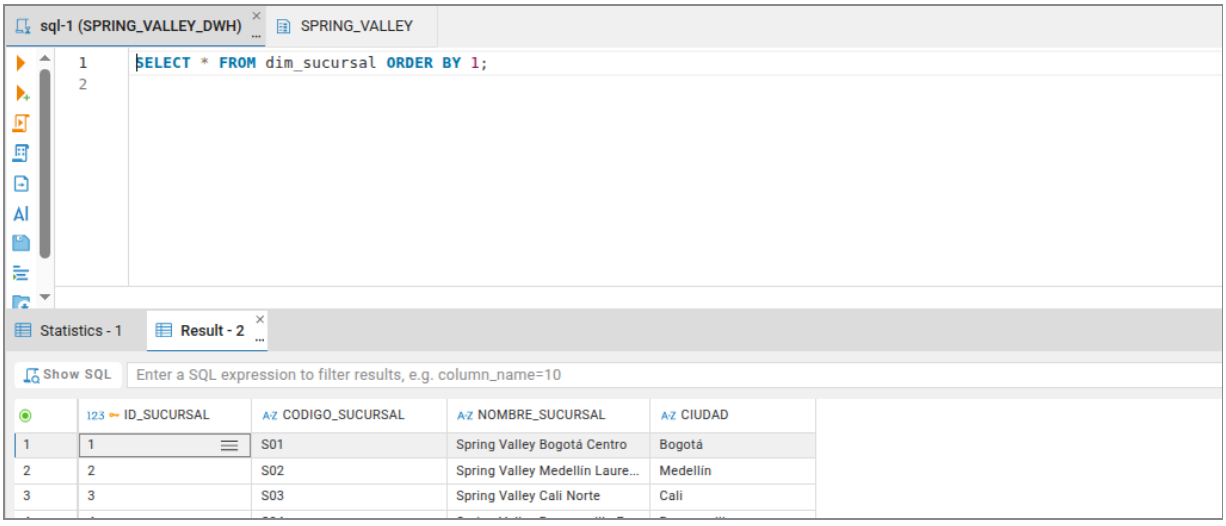
DIM_VENDEDOR cargada



Nota. Elaboración propia. La dimensión contiene los 8 vendedores (V01 a V08) con su nombre estandarizado.

Figura 25

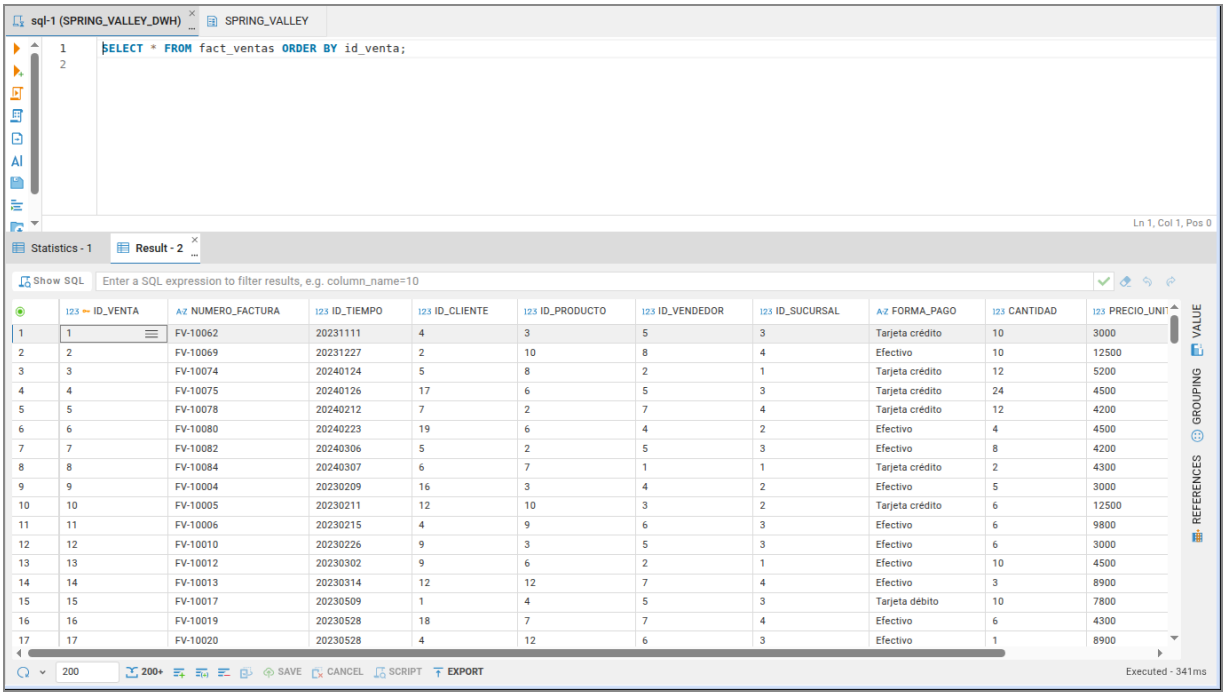
DIM_SUCURSAL cargada



Nota. Elaboración propia. Se observan las 4 sucursales de Spring Valley: Bogotá Centro, Medellín Laureles, Cali Norte y Barranquilla Prado, con su ciudad.

Figura 26

Tabla de hechos FACT_VENTAS cargada



Nota. Elaboración propia. Cada fila de FACT_VENTAS es una línea de factura con sus llaves numéricas hacia las dimensiones, la forma de pago estandarizada, la cantidad, el precio unitario y el valor total. Los textos descriptivos ya no se repiten en la tabla de hechos: se obtienen de las dimensiones mediante JOIN.

Validación de la información

Antes de analizar se validó la carga, como indicaron los instructores. La Tabla 9 resume los controles.

Tabla 9

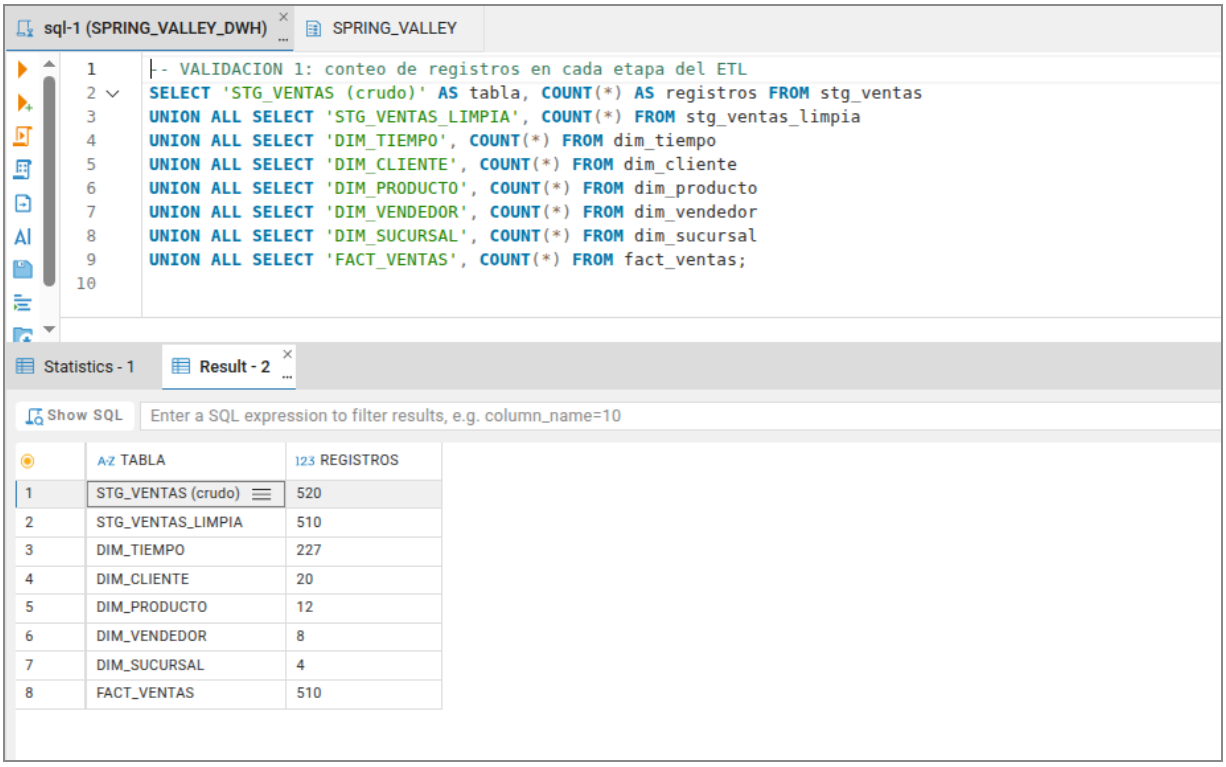
Resultados de la validación del ETL

Control	Resultado	Interpretación
Registros en staging crudo / limpio	520 / 510	Se eliminaron exactamente los 10 duplicados
Registros en FACT_VENTAS	510	Ninguna línea limpia se perdió en la carga

Dimensiones	227 fechas, 20 clientes, 12 productos, 8 vendedores, 4 sucursales	Sin duplicados
Líneas duplicadas en FACT_VENTAS	0	Se cumple el grano
Fechas o sexo nulos tras la limpieza	0	Los tres formatos de fecha se convirtieron
Valores de SEXO	F, M	Catálogo válido
Valores de FORMA_PAGO	Efectivo, Transferencia, Tarjeta crédito, Tarjeta débito	Catálogo válido
Rango de fechas	2023-01-02 a 2025-12-24	Tres años de historia
Ventas huérfanas (sin cliente / sin producto)	0 / 0	Integridad referencial completa
Total staging limpio vs. FACT_VENTAS	25.989.200 = 25.989.200	Métricas coherentes
Llaves primarias / foráneas	6 / 5	Modelo estrella completo

Figura 27

Validación de registros por etapa

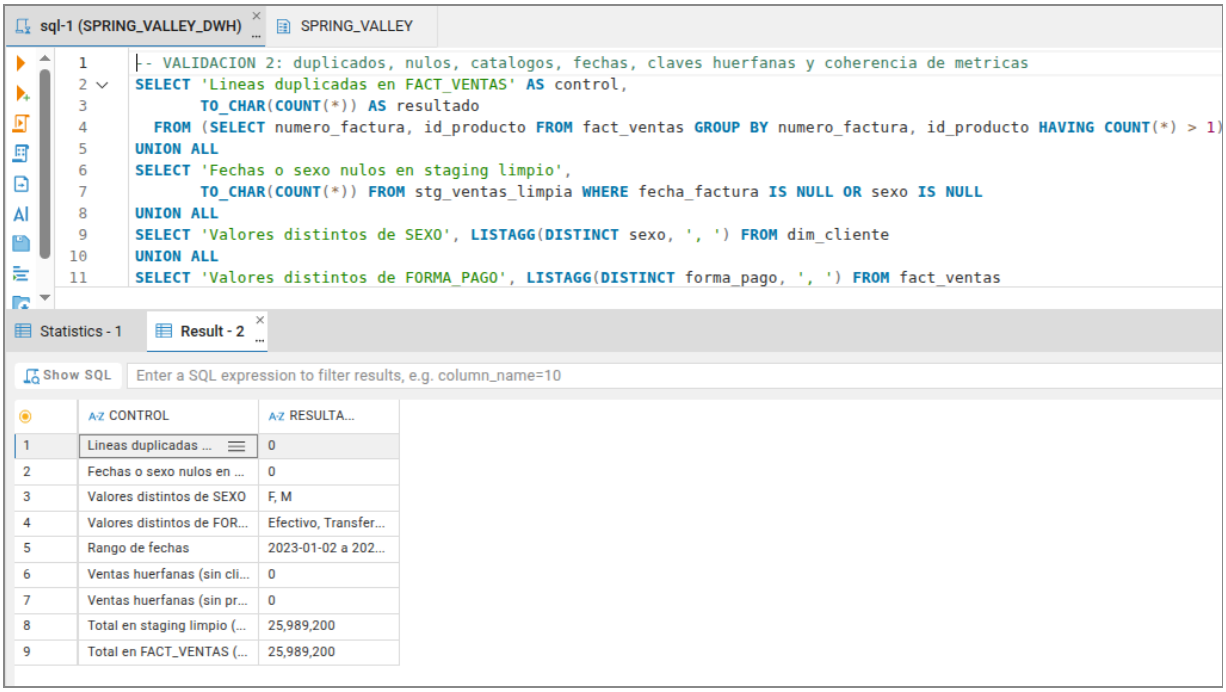


Nota. Elaboración propia. Con UNION ALL de varios COUNT(*) se compararon las etapas del ETL: 520 filas crudas, 510 limpias, 510 en FACT_VENTAS y el número de filas de cada

dimensión. La igualdad entre el staging limpio y la tabla de hechos demuestra que la carga fue completa.

Figura 28

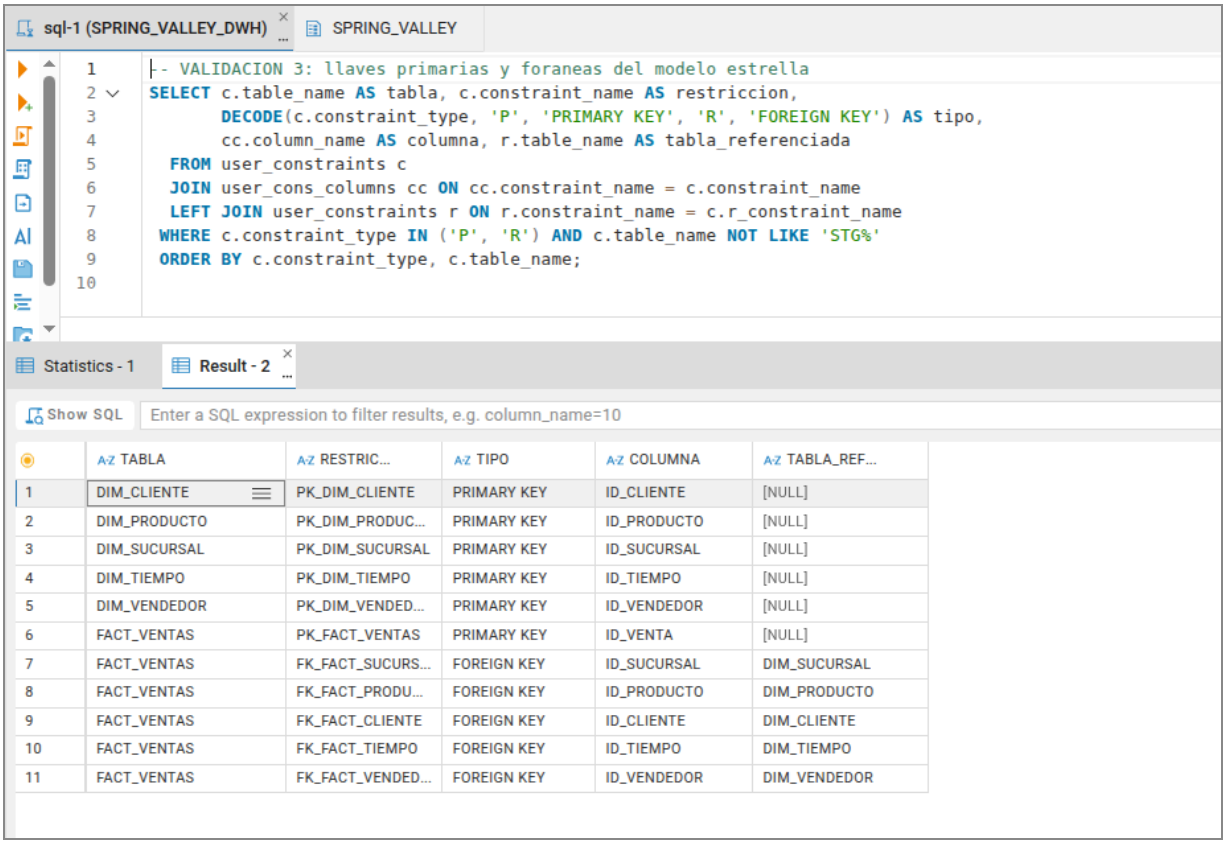
Validación de calidad: duplicados, nulos, catálogos y métricas



Nota. Elaboración propia. La consulta reúne nueve controles. Muestra 0 líneas duplicadas, 0 fechas o sexos nulos, los catálogos válidos de sexo y forma de pago, el rango de fechas, 0 ventas huérfanas y el mismo total (25.989.200) en el staging limpio y en FACT_VENTAS. La pantalla recorta algunos textos largos; el resultado completo está en logs/04_validacion_y_consultas.log y en la Tabla 9.

Figura 29

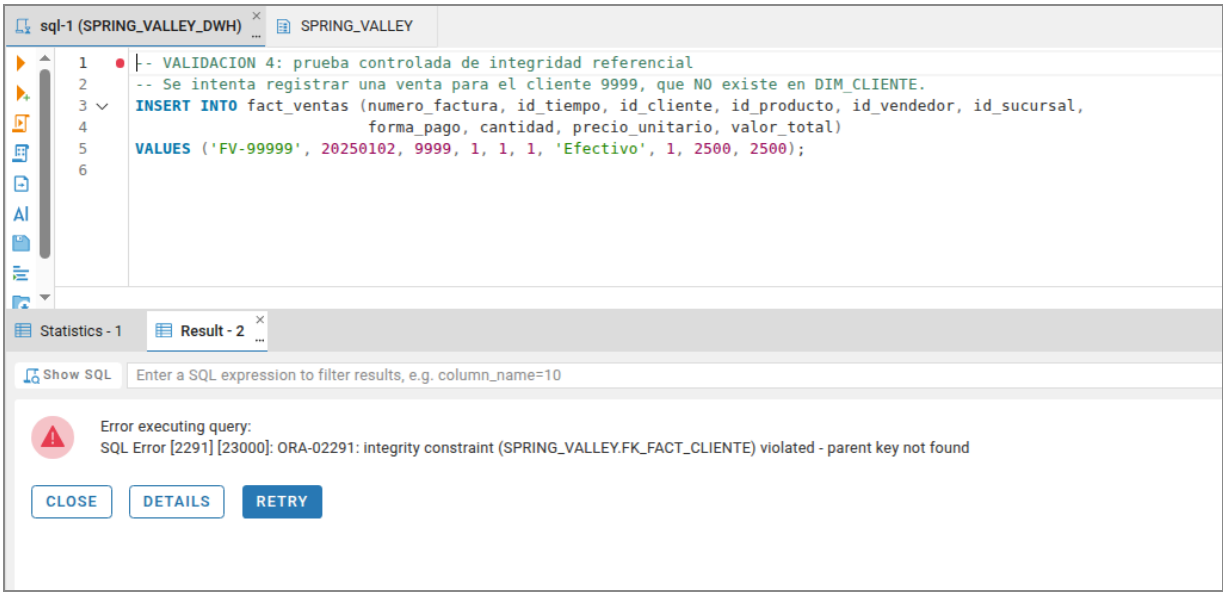
Validación de llaves primarias y foráneas



Nota. Elaboración propia. Desde las vistas USER_CONSTRAINTS y USER_CONS_COLUMNS se listaron las 6 llaves primarias (una por tabla del modelo) y las 5 llaves foráneas de FACT_VENTAS con su tabla referenciada. Esto confirma que la integridad referencial está definida en el motor y no depende de la aplicación.

Figura 30

Prueba de integridad referencial (ORA-02291)



Nota. Elaboración propia. Se intentó registrar una venta para el cliente 9999, que no existe en DIM_CLIENTE. Oracle la rechazó con «ORA-02291: integrity constraint (SPRING_VALLEY.FK_FACT_CLIENTE) violated - parent key not found». La consulta posterior confirmó que FACT_VENTAS siguió con 510 filas, de modo que los datos válidos no se alteraron. Esta prueba demuestra que la bodega no admite ventas sin contexto.

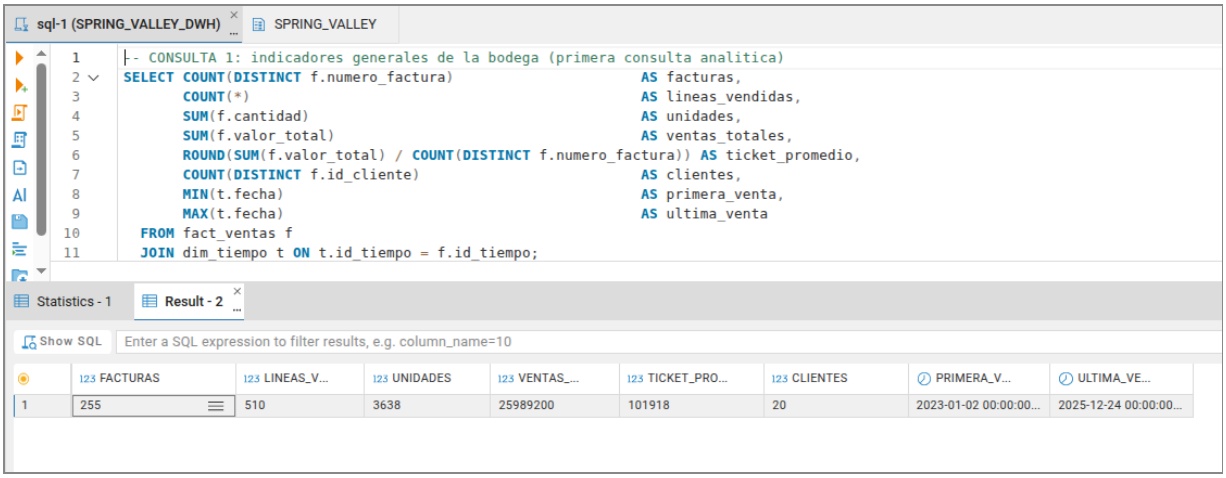
Consultas y análisis de negocio

Con la bodega validada se respondieron las preguntas del negocio. Todas las consultas unen FACT_VENTAS con sus dimensiones (JOIN), agrupan (GROUP BY) y calculan métricas (SUM, COUNT, AVG y funciones analíticas).

```
SELECT t.anio, COUNT(DISTINCT f.numero_factura) AS facturas, SUM(f.cantidad) AS unidades,
       SUM(f.valor_total) AS ventas, ROUND(AVG(f.valor_total)) AS promedio_por_linea,
       ROUND(100 * (SUM(f.valor_total) / LAG(SUM(f.valor_total)) OVER (ORDER BY t.anio) - 1), 1)
AS crecimiento_pct
  FROM fact_ventas f JOIN dim_tiempo t ON t.id_tiempo = f.id_tiempo
 GROUP BY t.anio ORDER BY t.anio;
```

Figura 31

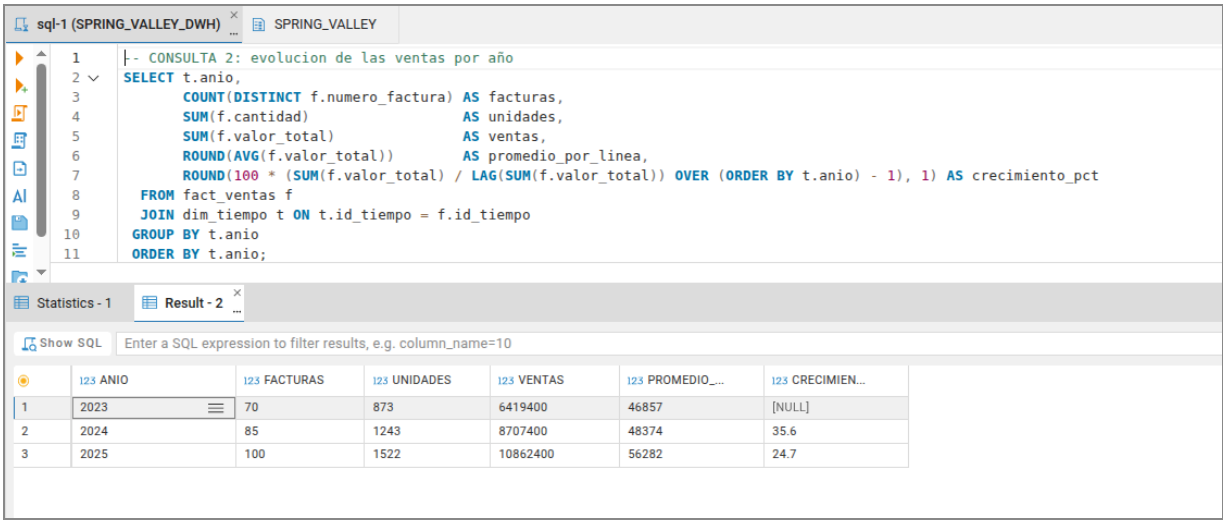
Primera consulta analítica: indicadores generales



Nota. Elaboración propia. La primera consulta resume la bodega: 255 facturas, 510 líneas, 3.638 unidades, ventas por $25.989.200, ticket promedio de $101.918 por factura y 20 clientes, entre el 2 de enero de 2023 y el 24 de diciembre de 2025. Estos indicadores son la línea base contra la que la dirección podrá medir resultados futuros.

Figura 32

Evolución de las ventas por año

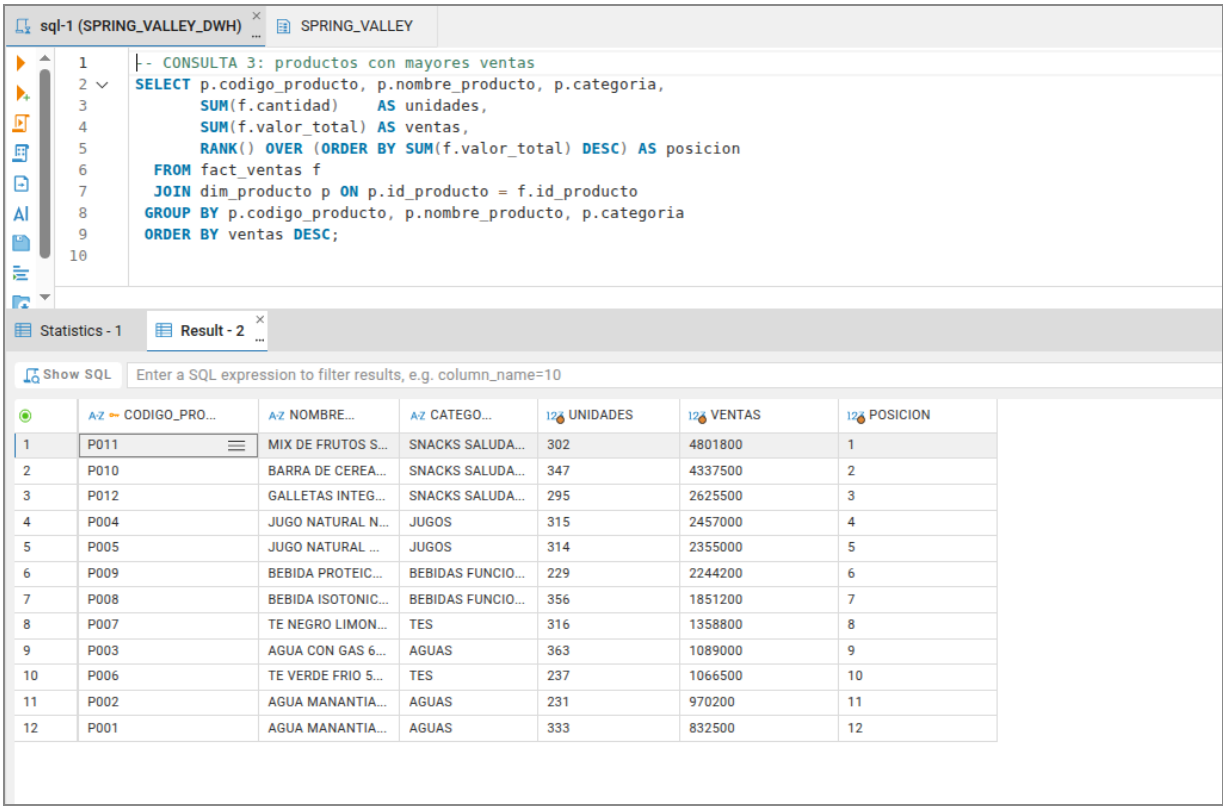


Nota. Elaboración propia. Uniendo FACT_VENTAS con DIM_TIEMPO y agrupando por año, las ventas pasaron de $6.419.400 (2023) a $8.707.400 (2024) y a $10.862.400 (2025). La función LAG calcula un crecimiento del 35,6 % en 2024 y del 24,7 % en 2025. El negocio

crece de forma sostenida, aunque a menor ritmo; además, el valor promedio por línea subió de $46.857 a $56.282. Esta tendencia sirve de base para pronosticar 2026 y planear compras e inventario.

Figura 33

Productos con mayores ventas

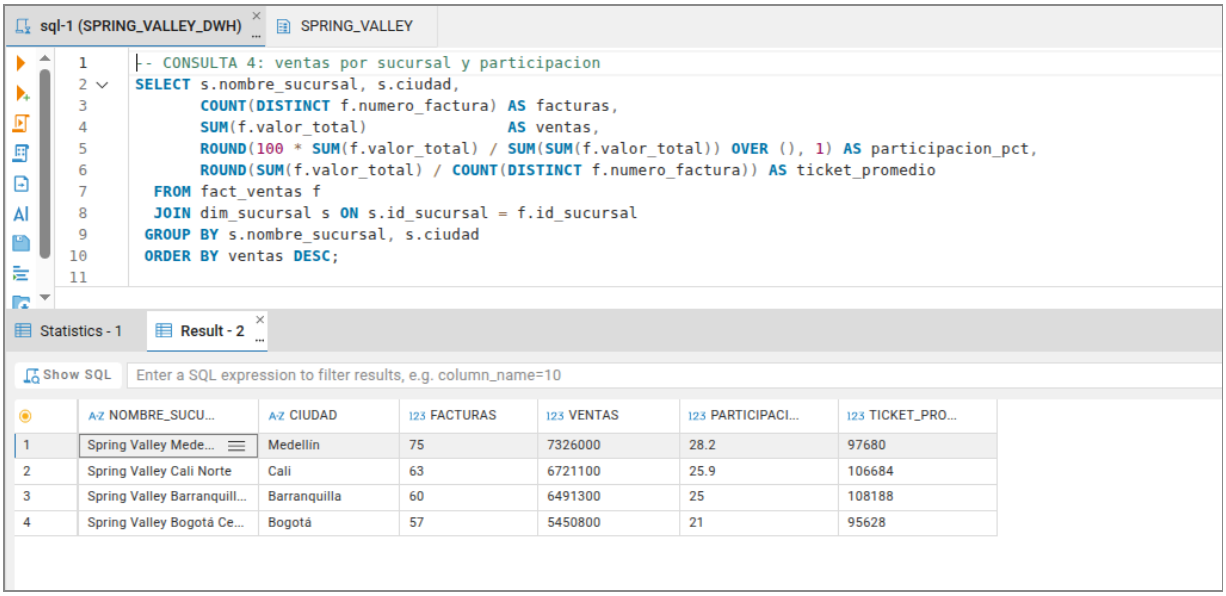


	CODIGO_PRO...	NOMBRE...	CATEGO...	UNIDADES	VENTAS	POSICION
1	P011	MIX DE FRUTOS S...	SNACKS SALUDA...	302	4801800	1
2	P010	BARRA DE CEREA...	SNACKS SALUDA...	347	4337500	2
3	P012	GALLETAS INTEG...	SNACKS SALUDA...	295	2625500	3
4	P004	JUGO NATURAL N...	JUGOS	315	2457000	4
5	P005	JUGO NATURAL ...	JUGOS	314	2355000	5
6	P009	BEBIDA PROTEIC...	BEBIDAS FUNCIO...	229	2244200	6
7	P008	BEBIDA ISOTONIC...	BEBIDAS FUNCIO...	356	1851200	7
8	P007	TE NEGRO LIMON...	TES	316	1358800	8
9	P003	AGUA CON GAS 6...	AGUAS	363	1089000	9
10	P006	TE VERDE FRIO 5...	TES	237	1066500	10
11	P002	AGUA MANANTIA...	AGUAS	231	970200	11
12	P001	AGUA MANANTIA...	AGUAS	333	832500	12

Nota. Elaboración propia. Con RANK() sobre SUM(valor_total), los tres primeros lugares corresponden a snacks saludables: Mix de frutos secos ($4.801.800), Barra de cereal ($4.337.500) y Galletas integrales ($2.625.500). Las aguas venden muchas unidades (Agua con gas, 363) pero poco valor por su bajo precio. Spring Valley debería priorizar el abastecimiento y la promoción de snacks y jugos, que generan más ingresos por unidad.

Figura 34

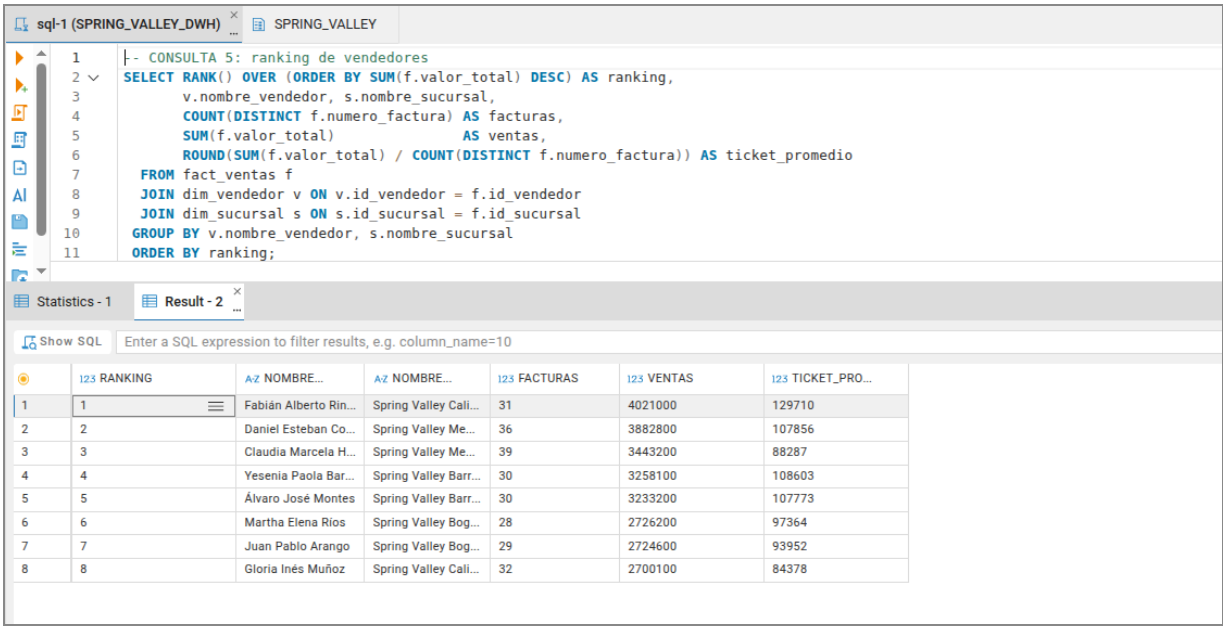
Ventas por sucursal



Nota. Elaboración propia. Medellín Laureles lidera con $7.326.000 (28,2 % de las ventas y 75 facturas), seguida de Cali Norte (25,9 %) y Barranquilla Prado (25,0 %); Bogotá Centro es la de menor participación (21,0 %) y menor ticket promedio ($95.628). La empresa podría replicar las prácticas de Medellín y revisar la estrategia comercial de Bogotá.

Figura 35

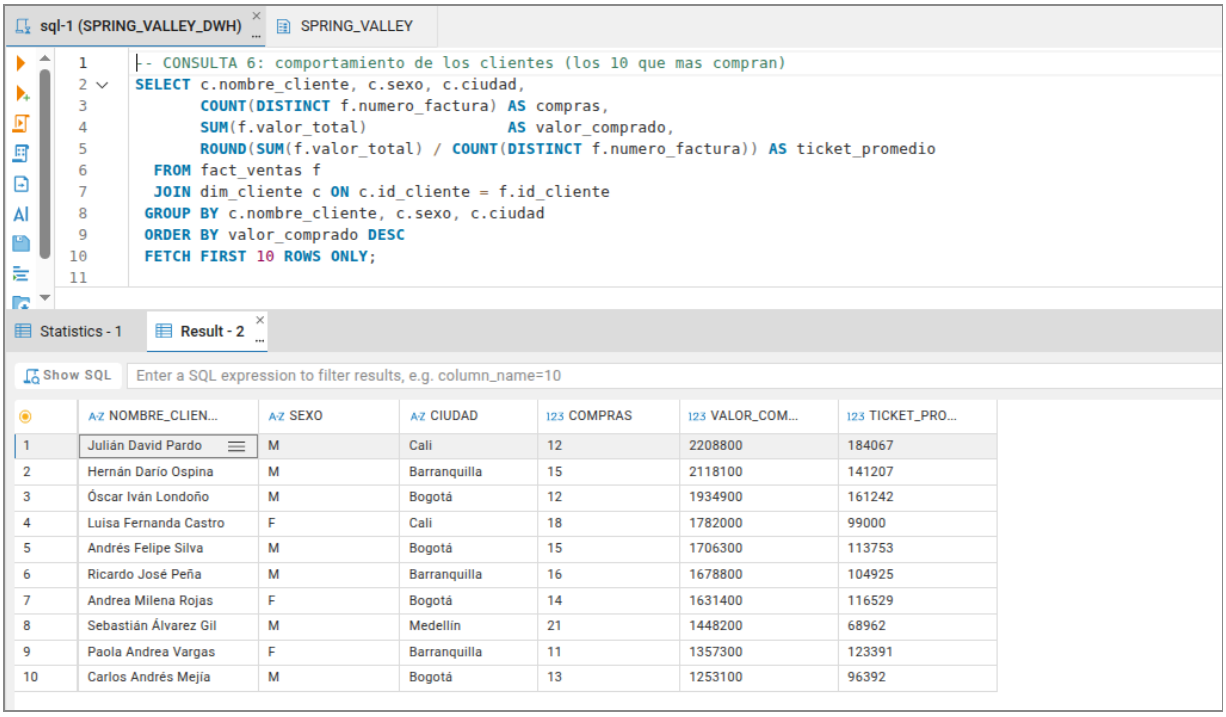
Ranking de vendedores



Nota. Elaboración propia. El ranking ordena a los vendedores por valor vendido. Fabián Alberto Rincón (Cali Norte) ocupa el primer lugar con $4.021.000 y el ticket promedio más alto ($129.710), aunque con menos facturas (31) que Claudia Marcela Henao (39). En la misma sucursal, Gloria Inés Muñoz ocupa el último lugar ($2.700.100), lo que muestra diferencias de desempeño que pueden orientar capacitaciones e incentivos.

Figura 36

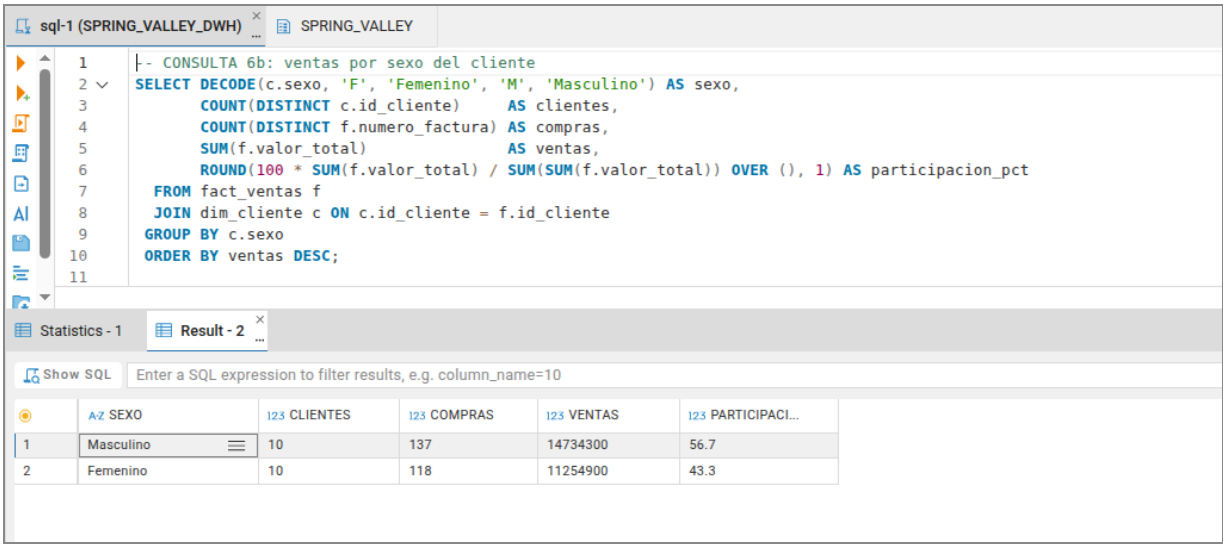
Clientes que más compran



Nota. Elaboración propia. Los 10 clientes con mayor valor comprado están encabezados por Julián David Pardo ($2.208.800 en 12 compras, ticket de $184.067). Sebastián Álvarez Gil es el que más veces compró (21), pero con un ticket bajo ($68.962). Esto sugiere dos estrategias: fidelizar a los clientes de alto ticket y aumentar el valor de compra de los clientes frecuentes.

Figura 37

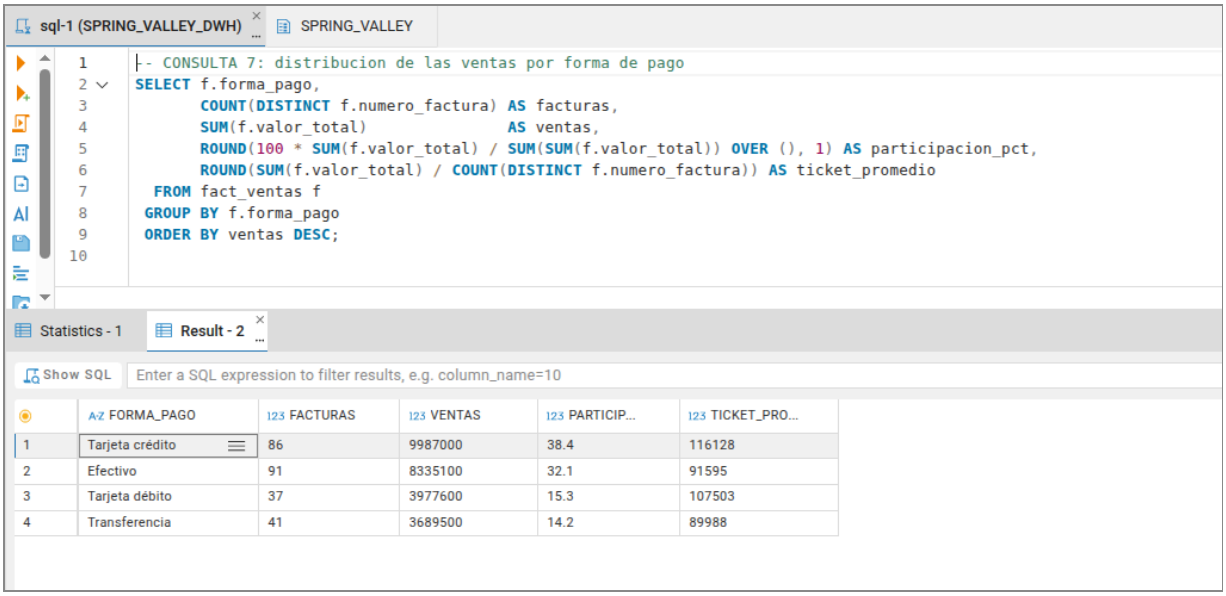
Ventas por sexo del cliente



Nota. Elaboración propia. Agrupando por el sexo ya estandarizado, los 10 clientes masculinos concentran el 56,7 % de las ventas y las 10 clientes femeninas el 43,3 %. Este análisis solo es posible porque el ETL convirtió las 10 formas de escribir el sexo en M y F.

Figura 38

Distribución de ventas por forma de pago



Nota. Elaboración propia. La tarjeta de crédito concentra el 38,4 % de las ventas con el ticket más alto ($116.128), aunque el efectivo tiene más facturas (91 frente a 86). Tarjeta débito (15,3 %) y transferencia (14,2 %) completan la distribución. Spring Valley puede usar este dato para negociar comisiones con los bancos y promover los medios electrónicos.

Resultados obtenidos

Tabla 10

Síntesis de resultados

Aspecto	**Resultado**
Bodega implementada	Esquema SPRING_VALLEY en Oracle con 1 tabla de hechos, 5 dimensiones y 2 tablas de staging
ETL	520 filas crudas → 510 filas limpias → 510 hechos; 10 duplicados eliminados
Calidad	Sexo: de 10 variantes a 2; forma de pago: de 16 variantes a 4; fechas: de 3 formatos a DATE
Integridad	6 PK, 5 FK, CHECK y UNIQUE; 0 huérfanos; ORA-02291 ante una venta inválida
Ventas 2023–2025	$25.989.200; crecimiento del 35,6 % en 2024 y del 24,7 % en 2025
Hallazgos	Snacks saludables lideran; Medellín es la sucursal principal; la tarjeta de crédito es la forma de pago de mayor valor
Rendimiento	Consultas analíticas resueltas entre 22 y 341 ms, sin tocar el sistema transaccional

Conclusiones

La construcción de la bodega de datos de Spring Valley demostró que separar el análisis del sistema transaccional resuelve el problema que originó el caso: las consultas históricas se ejecutan sobre un esquema propio, en milisegundos, sin competir con la facturación.

La metodología Kimball permitió pasar de las preguntas de la dirección a un diseño concreto. Declarar el grano (una línea de factura) fue la decisión más importante, porque definió qué representa cada fila y garantizó que las sumas por cualquier dimensión fueran correctas. El modelo estrella, con FACT_VENTAS y cinco dimensiones, resultó simple de consultar: cada pregunta se respondió con unos pocos JOIN y un GROUP BY.

El proceso ETL fue la etapa más exigente y la de mayor valor. Los datos crudos tenían 10 formas de escribir el sexo, 16 de escribir la forma de pago, tres formatos de fecha y filas duplicadas; con TRIM, UPPER, INITCAP, CASE y TO_DATE se estandarizaron por completo. Sin esa limpieza, los análisis habrían mostrado categorías falsas y totales inflados.

La validación y las restricciones de Oracle dieron confianza en los resultados: los conteos y totales coinciden entre etapas, no hay claves huérfanas y el motor rechazó una venta con un cliente inexistente. Finalmente, las consultas analíticas entregaron información útil para decidir: crecimiento sostenido, liderazgo de los snacks saludables y de la sucursal de Medellín, diferencias entre vendedores y preferencia por la tarjeta de crédito.

Oportunidades de mejora

- Automatizar el ETL con procedimientos PL/SQL y tareas programadas (DBMS_SCHEDULER) para no depender de ejecuciones manuales.
- Actualizar la bodega periódicamente (por ejemplo, cada noche) con cargas incrementales que solo traigan las ventas nuevas.
- Incorporar controles de calidad automáticos que detengan la carga si aparece un valor fuera de catálogo o una fecha inválida, y registrar las filas rechazadas en una tabla de

errores.

- Aplicar dimensiones de cambio lento (SCD tipo 2) para conservar la historia cuando un cliente cambie de ciudad o un vendedor de sucursal.
- Conectar herramientas de visualización (Power BI, Tableau u Oracle Analytics) para construir tableros para la gerencia.
- Definir políticas de respaldo (RMAN o Data Pump) y de recuperación de la bodega.
- Reforzar la seguridad: usuarios de solo lectura para analistas, contraseñas robustas y cifrado de conexiones.
- Planear el crecimiento: agregar nuevos procesos de negocio (inventario, compras) que compartan las dimensiones conformadas de tiempo, producto y sucursal, y particionar FACT_VENTAS por año cuando aumente el volumen.

Referencias

Arévalo Vela, M. A. (2026a, 22 de septiembre). *Resumen sesión en línea fase 1 análisis: Explicación evidencia técnica GA4-210602033-AA1-EV03* [Documento de sesión]. Servicio Nacional de Aprendizaje (SENA).

Arévalo Vela, M. A. (2026b, 23 de septiembre). *Resumen sesión en línea fase 1 análisis: Explicación evidencia técnica GA4-210602033-AA1-EV03, parte 2* [Documento de sesión]. Servicio Nacional de Aprendizaje (SENA).

DBeaver Corporation. (s.f.). *CloudBeaver documentation*. https://dbeaver.com/docs/cloudbeaver/

Fuel Tulcán, C. A. (2026a, 24 de septiembre). *Resumen sesión en línea: Explicación evidencia GA4-210602033-AA1-EV03, parte 3* [Documento de sesión]. Servicio Nacional de Aprendizaje (SENA).

Fuel Tulcán, C. A. (2026b, 25 de septiembre). *Resumen sesión en línea: Explicación evidencia GA4-210602033-AA1-EV03, parte 4* [Documento de sesión]. Servicio Nacional de Aprendizaje (SENA).

Inmon, W. H. (2005). *Building the data warehouse* (4.ª ed.). Wiley.

Kimball, R., y Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3.ª ed.). Wiley.

Oracle. (s.f.). *Oracle Database SQL language reference*. https://docs.oracle.com/en/database/oracle/oracle-database/23/sqlrf/

Oracle. (s.f.). *Oracle SQLcl user's guide*. https://docs.oracle.com/en/database/oracle/sql-developer-command-line/

Servicio Nacional de Aprendizaje (SENA). (s.f.). *Bodegas de datos* [Componente formativo]. Programa Implementación y gestión de bases de datos.

Anexo. Lista de chequeo de la evidencia

Tabla 11

Control final de requisitos

Requisito	**Cumple**	**Evidencia / sección**
Caso Spring Valley, área de ventas	Sí	Contexto; todo el documento
Planeación con línea de tiempo	Sí	Planeación, Tabla 1
Herramientas de hardware y software	Sí	Requerimientos técnicos, Tabla 3; Herramientas
Requerimientos de negocio, compañía y técnicos	Sí	Requerimientos, Tablas 2 y 3
Información relevante para ventas	Sí	Requerimientos del negocio; Hechos y dimensiones
Tablas, columnas, tipos de datos y relaciones	Sí	Diseño del modelo, Tabla 7; Figuras 13 a 18
Esquema estrella	Sí	Figuras 1 y 20
Staging y proceso ETL	Sí	Figuras 4 a 12
Dimensiones primero, hechos después	Sí	Figuras 11 y 12
Validación e integridad referencial	Sí	Tabla 9; Figuras 27 a 30
Capturas reales con interpretación	Sí	38 figuras con párrafo explicativo
Consultas de negocio interpretadas	Sí	Figuras 31 a 38
Conclusiones y oportunidades de mejora	Sí	Secciones finales
Referencias en APA 7	Sí	Referencias
Mínimo 8 páginas, formato PDF	Sí	Archivo PDF generado